

一种基于路径选择的多模态领域知识问答方法

王 向 李艳超 张晓明*

(河北科技大学信息科学与工程学院 河北 石家庄 050000)

摘 要 基于知识图谱的问答领域中存在着自然语言与结构化知识的差异性挑战,因此,提出一种利用谓词选择路径的方法 PMKBQA。构建多模态领域知识图谱和问题集;从问题中识别的主题实体出发,计算其边与问题谓词的相似度,以逐跳的方式生成答案路径,直到找到问题答案,并依据答案路径获取问题答案的相关图像;在领域问题集上做用户满意度评估实验,结果表明该方法可以给用户提供满意的图像,同时在 QALD 数据集上进行问答效果的对比实验,结果表明该方法比基线方法在 F1 指标上有所提升。

关键词 多模态知识图谱 问答 多模态问题集 路径选择

中图分类号 TP3

文献标志码 A

DOI:10.3969/j.issn.1000-386x.2025.04.028

PMKBQA: A MULTIMODAL DOMAIN KNOWLEDGE QUESTION ANSWERING METHOD BASED ON PATH SELECTION

Wang Xiang Li Yanchao Zhang Xiaoming*

(School of Information Science and Engineering, Hebei University of Science and Technology, Shijiazhuang 050000, Hebei, China)

Abstract There are different challenges between natural language and structured knowledge in the field of question answering based on knowledge graphs. Therefore, this paper proposes a method of using predicates to select paths (PMKBQA). A multimodal domain knowledge graph and question set were constructed. Starting from the subject entity identified in the question, calculating the similarity between its edge and the question predicate, and generating the answer path hop by hop until the answer to the question was found. Relevant images of the answer of the question according to the answer path were acquired. The user satisfaction evaluation experiment was done on the domain question set, and the results show that this paper can provide users with satisfactory images. Meanwhile, a question answering effect evaluation experiment is done on the QALD data set, and the results show that our method is better than the baseline method in F1.

Keywords Multimodal knowledge graph Questions answering Multimodal question Path selection

0 引 言

基于知识图谱的问答利用结构化知识作为背景知识库,通过问题理解来返回答案。随着一些特定领域知识图谱的出现,对问答提出了新的要求,不仅要依靠知识图谱找到领域问题的答案,还需要对答案进行解释,使用户可以更清楚地理解一些晦涩难懂的问题。利用多模态的知识,尤其是图像模态,可以更加直观地

为用户展示问题和答案之间的联系,对于一些难以用自然语言回答的问题,利用贴近语义的图像可以得到更清晰的回答。

为了对涉及图像问题进行回答,一些研究者^[1-3]提出了 KBVQA 方法,让用户自己输入一个问题和一个相关的图像,通过系统对图像进行识别处理,检测得到图像中的目标实体,利用实体对齐方法将该实体与知识图谱进行对齐,从而获得一个与用户提出的问题相关的局部知识图谱,最后利用知识图谱,对用户提出

的问题进行回答。例如 Wang 等^[3]构建了一个基于知识图谱的 VQA 数据集,并利用目标检测获得的图像中的实体与知识图谱中的实体进行实体消歧,从而获得问题的答案。

KBVQA 方法可以有效地对用户提出的与图像有关的问题进行回答,KBVQA 方法可以有效的对用户提出的与图像有关的问题进行回答,但是当用户没有相关图像,却期望系统返回相关图像来对一些晦涩难懂的领域问题进行直观表示时,是困难的。基于多模态知识图谱的问答可以为用户返回图像,而不要求用户提供图像^[4]。

多模态知识图谱中包含与图像相关的知识,只需要将问题中的图像提及词汇与知识图谱中的图像实体对应起来,就能够通过知识图谱来寻找问题的答案。基于多模态知识图谱的问答可以大幅度缩短问题回答的时间,而且对重复的问题获取图像信息时,不用重复图像检测和识别,并且可以通过多模态知识图谱获得问题相关的图像。例如 Li 等^[5]构建了一个多模态知识图谱,在返回答案的同时,返回相应的图像。但是该方法在处理图像关系时粒度较大,只是简单以“hasImage”关系进行连接,导致用户需要自己理解图像和问题之间的具体关系。

为了解决上述问题,提出一种基于路径选择的答案获取方法 PMKBQA。以计算机领域为例,利用多模态知识图谱实现不仅返回问题答案,还有序地返回相关图像的答案模式。CSO^[6]本体中存储着大量的计算机领域概念和概念之间的关系,本文在此基础上进行图像信息扩展。主要贡献如下:

(1) 基于 CSO 本体设计计算机领域多模态知识图本体 (IMKG),定义对图像资源和 CSO 实体的关联关系。设计多模态问题模板,构建多模态问题集 (CSQA)。

(2) 面向多模态问题,提出基于路径选择的答案获取方法 (PMKBQA)。在多模态知识图中,从问题中识别的主题实体出发,计算其边与问题谓词的相似度,以逐跳的方式生成答案路径,直到找到问题答案;并依据答案路径获取与答案相关的图像。

(3) 在 CSQA 数据集对 PMKBQA 方法进行满意度评估,实验结果表明,PMKBQA 可以提供满意的图像答案。在 QALD 数据集上进行对比实验,与基线模型相比,PMKBQA 方法提供问题答案的效果有提升。

1 相关工作

目前涉及到图像的基于知识图谱的问答方法,根

据用户是否提供图像分为两类,一类是用户提供图像的视觉问答^[7-8];另一类是用户不提供图像的混合问答^[9-10]。

传统的基于知识图谱的视觉问答,往往需要对图像进行知识抽取,利用实体对齐技术,将图像中的实体与知识图谱进行对齐,获得扩展的知识图谱之后,利用模板、构造 SPARQL^[11]或者生成查询图^[12-13]等方法从知识图谱中获取答案^[2-3,14-15]。例如 Wang 等^[3]提出了将图像进行目标检测获得图像实体之后,将其与知识图谱中的实体进行对齐,从而将知识图谱和图像知识结合起来,利用对问题解析方法,获得问题三元组,根据问题三元组的结构,构造 SPARQL 查询,从而获得答案。Shin 等^[16]设计了新的谓词字典,利用谓词限制主语和宾语的类型,通过生成查询图来回答问题。

当前基于知识图谱的视觉问答,可以利用深度学习模型,将视觉知识和问题文本进行向量化表示,在低维度空间进行答案搜索^[17-19]。例如 Li 等^[20]提出的深度学习模型,利用从外部知识图谱中检索给定图像和问题文本相关的知识,然后利用这些知识提高视觉问题的回答准确率。除此之外,随着知识图谱的发展,常识类问题也逐渐成为人们关心的问题,于是出现了一些基于图像提出的常识类问题,例如 Shah 等^[21]提出的常识性问题集,可以回答一些图像内容中有关的常识类问题。Zhan 等^[22]提出了通过对候选路径查找并分类的方法,来回答常识类问题。

混合问答方法^[9,23]不要求用户提供图像,但是需要回答与图像有关的问题,一般需要利用其他模态的知识,例如基于多模态知识图谱的问答^[24],在用户提出问题之前,需要先搜集图像并进行信息抽取,将图像与知识图谱中进行对齐^[5]。例如 Li 等^[5]将从 Wikipedia 中获取的图像与知识图谱利用“has_image”关系进行了链接,在回答用户问题时,获取该关系,从而返回给用户图像答案。

综上所述,视觉问答方法需要对用户输入的图像进行处理,用户等待时间往往较长,并且当重复输入同一个图像时,一般需要重复处理该图像,导致资源和时间的浪费。而且往往需要构造 SPARQL 查询,不利于处理规模庞大的数据集。混合问答方法在用户提问之前就将图像的信息与知识图谱进行了对齐,保证用户等待时间不会过长。

因此,基于混合问答方法,对问题进行解析获得问题三元组之后,不再构造 SPARQL,而是利用谓词在多模态知识图谱中进行问题答案路径选择,同时获得问

题答案和相关图像。

首先构建多模态知识图谱,但是在构建多模态知识图谱时不再简单使用“has_Image”关系进行简单的图像和知识图谱的连接,而是利用 Wikipedia 中的图像标题抽取图像与知识图谱中实体的具体关系,另外还对图像属性关系进行了抽取。除此之外,在回答问题时,保证问题答案准确的前提下,返回图像答案。这些图像答案不再是简单的问题中的实体相关图像,而是答案路径中所有的图像,并且将这些图像进行分类和排序,将候选答案返回给用户。

2 问题描述与概念定义

2.1 问题描述

回答多模态问题,一般需要用户提出一个多模态问题。首先找到问题中的主题实体,之后利用主题实体查询多模态知识图谱,最后找到答案子图,将答案划分为答案和相关图像返回给用户,如图1所示。这里涉及到了三个方面的问题,第一个是如何获得多模态问题和多模态知识图谱,第二个是如何获得问题中的主题实体,第三个是如何获得答案和相关图像。




图1 多模态问题描述

2.2 概念定义

定义1 多模态问题。指用户提出的问题中涉及到了图像,但不需提供图像的问题。

定义2 主题实体,记为 $T_{\text{topicEntity}}$ 。指多模态问题中最主要的实体。在问答时,需要按照主题实体来对知识图谱进行查找。

定义3 图像实体,记为 $I_{\text{imageEntity}}$ 。指多模态知识图谱中的图像。

定义4 图像关系,记为 $I_{\text{imageRelation}}$ 。知识图谱中与

图像实体相关的关系的总称,满足式(1)的条件。

$$I_{\text{imageRelation}} = I_{\text{imageR}} \cup I_{\text{imageP}} \quad (1)$$

式中: I_{imageR} 是 CSO 实体与图像之间的关系, I_{imageP} 是图像的属性。

3 PMKBQA 方法

3.1 多模态数据集

1) 构建多模态知识图谱。CSO 本体是关于计算机领域中的一些基础概念及其之间的关系的本体,本文在此基础上构建多模态知识图谱(IMKG)。首先在 CSO 的 Schema 层中加入图像类 TopicImage;然后在实例层中加入图像关系(ImageRelation),包括 CSO 实体与图像之间的关系(ImageR)和图像属性(ImageP);最后形成如图2所示的多模态知识图谱的结构,其中 Thing 是 CSO 本体中的根节点。




图2 IMKG 结构

(1) 图像类。CSO 的 Schema 层中对 CSO 实体的资源描述抽象为 Topic 类,本文加入的图像实体与 CSO 实体应该是并列关系,所以将所有的图像实体的顶级资源描述定义为 TopicImage 类。利用 YOLOv5^[25] 对图像进行目标检测,获得图像中的实体。本文重点关注以下五类实体:电脑(Computer)、鼠标(Mouse)、键盘(Keyboard)、人(People)和实验结果图(Experiment result)。对这五类实体进行分类,获得表1中的图像子类。其中将图像实体为 Computer、Mouse、Keyboard 的图像定义为 ImageHardware 类,将图像实体为 People 的图像定义为 ImagePeople 类,将图像实体为 Experiment result 的图像定义为 ImageResult 类。在实例层中利用从 Wikipedia 页面中获得的图像 id 对图像进行表示。图像 id 由 CSO 实体以及 Wikipedia 页面中图像的序号组成,例如 Computer science 页面中的第6幅图像表示为 Computer science_6。

表 1 图像类型分类结果

图像实体	图像子类	图像类
Computer	ImageHardware	TopicImage
Mouse		
Keyboard		
Person	ImagePeople	
Experiment result	ImageResult	

(2) ImageR。利用 OpenIE^[26] 对图像标题进行知识抽取,获得谓词。对获得的谓词进行分析,发现大部分都是与 with、work、use、have、is、above、behind、design 等词汇有关,所以根据这些词汇,形成了 6 个关系,利用表 1 中的关键字,对这些谓词进行分类,获得了 1~6 幅图像关系。还有一小部分不在这些分类中,谓词种类多变,没有办法根据关键字进行归类,因此将这类关系定义为 image_HasProperty。综上所述,获得了表 1 中的图像的对象属性,即 Object properties,共 7 种。

(3) ImageP。利用图像的 URL 截取图像名字字段,获取图像名称属性 (image_Name),然后将 URL 与图像实体以 image_URL 属性链接起来,并利用 OCR^[27] 对图像进行文字识别,获取图像文字属性 (image_HasWord),最后将图像标题和图像连接起来,获得图像标题属性 (image_Title)。最终获得了表 2 中的图像的数据属性,即 Data type properties,共 4 种。

表 2 对关系进行分类的结果

图像	关键字	图像关系	序号	数据
ImageR	is, are	image_IsA	1	Object properties
	bearing, with	image_MadeOf	2	
	work, use, for, be used to	image_BeUsedTo	3	
	develop, design	image_DevelopedBy	4	
	have, hers, his	image_HasA	5	
	各个方向	image_HasLocated	6	
	其他	image_HasProperty	7	
ImageP	图像名字	image_Name	8	Datatype properties
	图像 URL	image_URL	9	
	图像中的文字	image_HasWord	10	
	图像标题	image_Title	11	

为了理解上述步骤,给出了图 3 所示的构建 IMKG 的示例,以 Computer science 作为 CSO 实体,获取与其有关的图像知识。




图 3 多模态知识图谱构建示例

图 3 中将图像 id 作为图像实体的表示,利用 image_URL 属性指明图像,利用 OCR 识别了图像中的文字,获得了 image_HasWord 属性,利用图像 URL 获得了 image_Name 属性,以及图像标题直接相连获得了 image_Title 属性。利用 OpenIE 对图像标题进行知识抽取,获得了三元组为 <The famous P = NP? problem, is an open problem in, Computer science>, 因为谓词中含有 is, 根据表 1 将谓词替换为 image_IsA, 从而将图像和 CSO 实体连接起来。

2) 构建多模态问题模板。本文的目标是对问题进行回答的同时,有序地返回问题的图像答案。所以对多模态问题提出了两个要求:(1) 可以回答与图像有关的特有问题;(2) 可以回答与图像无关的一般性问题。无论是特有问题还是一般性问题,都需要在答案中返回相关图像。

因此,从这两个方面考虑,构建了多模态问题集 (CSQA),包括图像直接相关问题和图像间接相关问题。图像直接相关问题是对图像进行提问,问题答案是图像实体或者图像属性,记为 IQ。图像间接相关问题是是一般性问题,问题中不涉及到图像,问题答案是 CSO 实体,记为 I²Q。

为了构建 CSQA,让 10 个用户分别提出了一些问题,对这些问题进行归纳总结,获得了 30 种不同的问题模板,如表 3 所示,利用 IMKG 中的实体替换表中 \$e, 就可以获得两类不同的问题,这些问题模板中 IQ

是特有问題, I^2Q 是一般性问題, 在进行领域迁移时, 可以直接使用 I^2Q 的问題模板, 并参考 IQ 提出其他领域的特有问題。

表 3 多模态问題模板

问題模板	问題类型
What developed the concept similar of \$e? What does the image of \$e represent? What is the equivalent entity name of entity \$e? What is \$e made of? What is \$e generally used for? Is there any text on the image about \$e? Are there any related images about \$e? Is there any relevant image about \$e? ...	IQ
Which concept is equivalent to \$e? Which concept and \$e are equivalent? What is the contribution of \$e? ...	I^2Q

表 3 中只给出了部分模板, 这两类问題都需要返回图像答案, 所以所有的问題都是多跳的复杂问題。最终利用上述模板, 生成了共有 200 个问題的 CSQA 问題集。

3.2 谓词和主题实体识别

本文通过利用主题实体到 IMKG 中进行映射, 找到唯一相对应的实体, 从而获得答案。因此需要解决主题实体识别的问題。现有的工具, 例如 OpenIE、TagMe^[28] 等, 都可以有效地将问題中的实体识别出。但是这些工具都是针对开放领域中的实体, 对于计算机领域中的一些专有词汇, 很难将其准确地识别出来。为了准确识别出 CSQA 中的主题实体, 提出了基于语义解析的谓词和主题实体识别方法。

1) 获得 I^2Q 谓词和主题实体。利用 Stanford CoreNLP^[29] 对 CSQA 进行语义解析, 获得问題的 POS^[30] 标记和依存关系依存关系由 $Relation(en1, en2)$ 表示, 代表 $en2$ 到 $en1$ 的关系为 $Relation$ 。依存关系具有传递性。

在依存关系中, 将与主语有关的关系 ($subj, nsubj, nsubj:pass, csubj, csubjpass, xsubj$ 和 $poss$) 定义为主语关系, 记为 R_{sub} 。将与宾语有关的关系 ($obl, obj, pobj, dobj$ 和 $iobj$) 定义为宾语关系, 记为 R_{obj} 。本文利用这两种关系按照式(2)进行三元组的获取。

$$\forall r_1(x_1, y_1) \forall r_2(x_2, y_2) (r_1 \in R_{sub} \wedge r_2 \in R_{obj} \wedge IsEqual(x_1, x_2)) \rightarrow ((y_1, x_1, y_2) \in Q_{Ts}) \wedge (<x_1> \in P)$$

(2)

式中: x, y 表示单词, 且是完整的命名实体。完整的命

名实体指有连续的几个单词的 POS 标记都是 NN 或者 NNP 等名词属性, 且具有复合名词关系 ($compound$) 时, 将其视为整体。 r 表示依存关系, Q_{Ts} 是问題三元组集合, P 是谓词集合。 $IsEqual(x_1, x_2)$ 是判断 x_1, x_2 是否相等。式(2)表示当主语关系的第一个单词(x_1)和宾语关系的第一个单词(x_2)相等时, 表示主语和宾语与同一个谓词有关, 可以获得问題三元组, 并将三元组中的谓词加入到 P 中。

此时主题实体应该是主语或者宾语, 当主语为疑问词时, 主题实体为宾语, 如果宾语为疑问词, 那么主题实体为主语。例如 $<what, same, artificial\ intelligence>$, 因为主语为疑问词 $what$, 则宾语为主题实体。

例如一个问題: What is the concept equivalent to Artificial intelligence? 因为 Artificial 和 intelligence 这两个单词的 POS 标记分别为 NNP 和 NN, 且存在依存关系 $compound(intelligence, Artificial)$, 所以可以获得完整的命名实体 Artificial intelligence。 R_{sub} 为 $nsubj(equivalent, What)$, R_{obj} 为 $obl(equivalent, Artificial\ intelligence)$, 可以生成问題三元组 $<What, equivalent, Artificial\ intelligence>$, 谓词 $P = <equivalent>$ 。主题实体为 Artificial intelligence。

2) 抽取 IQ 的谓词和主题实体。通过以上两步可以获得 I^2Q 问題三元组, 但是 IQ 往往涉及到两个谓词, 需要通过一个谓词找到 CSO 实体之后, 通过另一个谓词找到答案。因此本文给出了抽取 IQ 问題三元组的规则, 如式(3)所示。

$$\forall r_1(x_1, y_1) \forall r_2(x_2, y_2) \forall r_3(x_3, y_3) \forall r_4(x_4, y_4) (r_1 \in R_{obj} \wedge r_2 \in R_{amod} \wedge r_3 \in R_{sub} \wedge r_4 \in R_{obj} \wedge (\neg IsEqual(r_1, r_4) \wedge IsEqual(x_1, y_2) \wedge IsEqual(x_3, x_4)) \rightarrow ((x_2, x_1, y_1) \in Q_{Ts}) \wedge (y_3, x_3, y_4) \wedge (<x_2, x_3> \in P))$$

(3)

式中: P 表示谓词集合, Q_{Ts} 表示问題三元组集合。式(3)表示除了利用问題中的主语关系和宾语关系之外, 还利用形容词关系, 即 $amod$ 。当有一个主语关系, 两个不同的宾语关系和一个形容词关系时, 且宾语关系的第一个单词(x_1)和形容词关系的第二个单词(y_2)相同时, 表明形容词用来修饰宾语, 即可获得形容词三元组。当主语关系(r_3)的第一个单词(x_3)和宾语关系(r_4)的第一个单词(x_4)相同时, 表明这两个单词指向同一个谓词, 可以获得问題三元组, 按顺序存放这两个三元组以及相应的谓词。

因为问題三元组是按照依存关系的顺序存放, 所以主题实体应在第一个问題三元组中。第一个问題三元组的主语为形容词, 所以宾语为主题实体。

例如一个问题:What developed the concept similar of Artificial intelligence? 其存在的完整的命名实体有 Artificial intelligence。 r_1 为 obl(similar, Artificial intelligence), r_2 为 amod(concept, similar), 可以获得形容词三元组 $\langle \text{concept}, \text{similar}, \text{Artificial intelligence} \rangle$ 。 r_3 为 nsubj(developed, What), r_4 为 obj(developed, concept), 得到问题三元组 $\langle \text{What}, \text{developed}, \text{concept} \rangle$, 最后获得的谓词为 $P = \langle \text{similar}, \text{developed} \rangle$ 。主题实体为 Artificial intelligence。

3.3 路径选择

1) 答案模式。本文的目标是在返回问题答案的同时, 返回相关图像。为了实现这一目标, 需要找到指明问题答案的路径, 给出了如下的定义来对答案和路径进行描述。

定义 5 多模态答案, 记为 E_{MM} 。指在回答多模态问题时, 为用户返回问题答案和图像答案, 满足:

$$E_{MM} = E^q \cup E^i \quad (4)$$

式中: E^q 为问题答案, 是对问题的回答, E^i 为图像答案, 指与主题实体到问题答案路径中的节点有关的所有图像, 是对问题答案的图像补充, 表示为 $\langle e_1^i, e_2^i, \dots \rangle$, 其中 e^i 表示 IMKG 中的图像实体, 例如图 4 中的图像答案为 $\langle e_8, e_9, e_{11}, e_{10} \rangle$ 。图像答案满足式 (5) 的条件。

$$E^i = E_a^i \cup E_b^i \quad (5)$$

式中: E_a^i 是主要图像答案, 由问题答案的相关图像组成, E_b^i 是次要图像答案, 由主题实体到问题答案的路径中, 除去问题答案节点的其他节点的相关图像组成。




图4 路径描述

定义 6 问题答案路径, 记为 OriginalPath。是主题实体到问题答案的路径, 用于指明问题答案, 表示为 $\langle T, r_1, e_1, r_2, e_2, r_3, \dots, r_k, e_A \rangle$, 其中: T 是主题实体, e 是 IMKG 中的实体, r 是 IMKG 中的关系, e_A 是问题答

案, 例如图 4 中的 $\langle e_1, r_2, e_2, r_4, e_3 \rangle$, e_1 为主题实体, e_3 为问题答案。

2) 获取多模态答案路径。因为寻找多模态答案路径是一个多跳的复杂问题, 本文参考 Shin 等^[16]的方法, 通过谓词来选择路径, 从而获得问题答案。不同的是不再构建谓词字典, 而是根据谓词逐跳地选择路径, 从而获得答案。

对于 I^2Q , 需要经过一跳或者多跳才能获得问题答案。因此, 在生成问题三元组时, 只会有一个问题三元组。而对于 IQ , 因为在 IMKG 中, 只经过两跳就可以获得图像, 所以会有两个问题三元组, 在每一跳路径中需要利用对应的三元组的谓词来进行路径选择。获得问题答案路径的具体步骤如图 5 所示。




图5 路径选择流程

Step1 获取主题实体和谓词。利用主题实体识别算法可以从问题三元组中获得主题实体 (TopicEntity)。对于 I^2Q , 谓词的长度为 1, 而对于 IQ , 谓词的长度为 2。因为在生成问题三元组的时候, 对问题三元组按照依存关系进行了排序存放, 所以只需要按照谓词的顺序进行处理即可, 并在首次获取谓词时, 将第一个元素作为起始谓词, 即 $p = P[1]$, p 是本跳中的谓词。

Step2 获得单跳候选答案路径并对多模态问题进行分类。

(1) 从 IMKG 中获得以主题实体为头实体的所有距离为 1 的边集合 R 。

(2) R 不为空时, 将每个边与谓词利用 SimCSE^[31] 计算谓词相似度, 并利用式 (6) 根据谓词相似度获得 RCandidate。SimCSE 通过简单的 Dropout 对文本进行向量表征学习, 比直接利用预训练的 Bert 进行向量表征学习, 大幅度提高了特征空间分布的均匀性。

$$R_{Candidate} = \underset{\langle t, r, e \rangle \in R}{\operatorname{argwhere}} (SimCSE(p, r) \geq \theta) \quad (6)$$

$$R_{Max} = \underset{\langle t, r, e \rangle \in R}{\operatorname{argmax}} (SimCSE(p, r))$$

式中: $R_{Candidate}$ 是单跳候选路径集合; R_{Max} 是谓词相似度

最大边; p 是谓词, $\langle t, r, e \rangle$ 是一条边, t 是主题实体, r 是一跳关系, e 是 r 的尾实体; θ 为阈值; argwhere 方法获取 p 和 r 的谓词相似度大于阈值的所有边; argmax 方法获得所有谓词相似度最大的边。式(16)表示, 将所有谓词相似度大于阈值的边存入 $R_{\text{Candidate}}$ 中, 将谓词相似度最大的边存入 R_{Max} 中。

- (3) 判断谓词的个数是否为 1, 当为 1 时, 该多模态问题为 I^2Q , 执行 Step3; 否则为 IQ , 执行 Step4。
- (4) 当 R 为空时, 则该主题实体是叶子节点, 认为没有答案, 直接结束。

Step3 获得 I^2Q 问题答案。

(1) 当 $R_{\text{Candidate}}$ 为空时, 证明没有找到与谓词相匹配的边, 即没有找到问题答案, 此时选择谓词相似度最大的边 (R_{Max}) 加入到问题答案路径中 ($O_{\text{originalPath}}$), 并将该边的尾实体作为新的主题实体, 并执行 Step2, 继续寻找与谓词相匹配的边。

(2) 当 $R_{\text{Candidate}}$ 的个数大于等于 1 时, 表明找到了问题答案, 此时执行剪枝后, 即可获得答案。利用式(7)进行剪枝。

$$\forall \langle t, r, e \rangle \in \left(\text{HasIntersection} \left(\text{Imagetype}(e), \text{Imagetype}(T_{\text{opicEntity}}) \right) \right) \rightarrow \langle t, r, e \rangle \in O_{\text{originalPath}} \quad (7)$$

式中: $\langle t, r, e \rangle$ 是 $R_{\text{Candidate}}$ 中的元素; Imagetype 方法用于获取实体的图像类型, 因为一个实体可能有多个图像, 并且一个图像中可能存在多个实体, 因此图像的类型也会有多个; HasIntersection 判断 e 和 $T_{\text{opicEntity}}$ 的所有相关图像的类型是否有交集。式(7)表示, 当主题实体相关图像的类型和边的尾实体的相关图像的类型有交集时, 将该边加入到 OriginalPath 中, 如果剪枝后的结果仍然有多个, 那么就按相似度对边进行排序, 依次加入到 OriginalPath 中。

Step4 获得 IQ 问题答案。

- (1) 当 $R_{\text{Candidate}}$ 的个数大于等于 1 时, 证明找到了与当前谓词相匹配的边, 通过剪枝之后, 获得唯一匹配边; 否则认为没有找到, 需要将 R_{Max} 加入到 $O_{\text{originalPath}}$ 中。
- (2) 如果当前谓词 p 是谓词集合的第一个元素, 证明第一个谓词匹配结束, 需要对第二个谓词进行匹配, 因此将 $O_{\text{originalPath}}$ 的最后一个元素作为新的主题实体, 并将谓词 p 更新为 P 的第二个元素, 并执行 Step2。
- (3) 如果当前谓词 p 为谓词集合的第二个元素, 证明每个谓词都已经寻找完毕, 结束程序。

本文给出了图 6 所示的示例, 利用上述步骤获取问题答案路径, 其中问题为: What developed the concept equivalent to anti-malware? 获得问题三元组 $\langle \text{concept},$

equivalent, anti-malware $\rangle$, $\langle \text{what}, \text{developed}, \text{concept} \rangle$, 其中谓词 $P = \{\text{equivalent}, \text{developed}\}$, 阈值设置为 0.5。




图 6 获取路径示例

该问题需要经过两跳才能找到答案, 为了更清晰地描述每一跳的路径更新情况, 给出了表 4 所示的路径更新步骤。

表 4 路径更新示例

$T_{\text{opicEntity}}$	p	$R_{\text{Candidate}}$	R_{Max}	$O_{\text{originalPath}}$
T	$P[1]$	Null	r_3	$\{ \langle T, r_3, A \rangle \}$
A	$P[2]$	r_1	r_1	$\{ \langle T, r_3, A \rangle, \langle A, r_1, i_{d2} \rangle \}$

表 4 中 $P[1] = \text{equivalent}$, $P[2] = \text{developed}$ 。在主题实体为 T 时, $R_{\text{Candidate}}$ 为空, 选择 R_{Max} 加入到答案路径中。当主题实体为 A 时, 将 $R_{\text{Candidate}}$ 加入到答案路径中。经过两跳获得 $O_{\text{originalPath}} = \{ \langle T, r_3, A \rangle, \langle A, r_1, i_{d2} \rangle \}$, 最后对 $O_{\text{originalPath}}$ 进行标准化处理, 获得 $O_{\text{originalPath}} = \langle T, r_3, A, r_1, i_{d2} \rangle$ 。 $O_{\text{originalPath}}$ 的最后一个元素为问题答案, 即 $E^q = \langle i_{d2} \rangle$ 。

3) 获得图像答案。上述方法可以获得答案路径和问题答案, 还需要根据答案路径获得图像答案, 并对图像答案进行分类和排序。

(1) 获取主要图像答案。利用式(8)获得主要图像答案:

$$E_a^i = \text{getImage}(e_A) \quad (8)$$

式中: e_A 是问题答案, $\text{getImage}(e_A)$ 是获取问题答案的所有相关图像。对于 I^2Q , 问题答案为 CSO 实体, 则主要图像答案是与问题答案相关的图像实体的对应图像。例如图 4 中问题答案是 e_3 , 与 e_3 相关的图像实体是 e_6 和 e_7 , 它们对应的图像分别是 e_{11} 和 e_{10} , 即 $E_a^i = \langle e_{11}, e_{10} \rangle$ 。对于 IQ , 问题答案为图像实体, 则主要图像答案为问题答案的图像。例如图 6 中, 问题答案为 i_{d2} , 是图像实体, 那么主要图像答案为 i_{d2} 的图像, 即 $E_a^i = \langle i_{d2} \rangle$ 。

(2) 获取次要图像答案。利用式(9)获得次要图像答案:

$$\begin{aligned}\vec{E} &= getEntitylist(O_{\text{riginalPath}}) \\ E_b^i &= \bigcup_{e_k \in \vec{E}[e_T, e_A]} getImage(e_k)\end{aligned}\tag{9}$$

式中: $getEntitylist$ 方法获取 $O_{\text{riginalPath}}$ 中的所有实体节点, 将其有序地存入到实体序列 $\vec{E}$ 中; e_T 是主题实体, e_A 是问题答案, $\vec{E}[e_T, e_A]$ 表示从 e_T 到 e_A 的所有节点, 包括 e_T , 不包括 e_A 。例如图 4 中主题实体到问题答案的路径中的节点有 e_1, e_2, e_3 , 去除问题答案节点, 剩余节点为 e_1, e_2 , 与 e_1, e_2 有关的图像实体为 e_4, e_5 , 则 $E_b^i = \langle e_8, e_9 \rangle$ 。

(3) 基于距离对图像答案排序。将利用上述方法获得的图像答案根据与问题答案的距离进行排序, 将靠近问题答案的图像排在前面。例如图 6 中的次要图像答案为 $E_b^i = \langle i_4, i_1, i_3 \rangle$, 因为 i_1 与 i_4 距离问题答案的距离为 4, 而 i_3 与问题答案的距离为 3, 所以更新图像答案为 $E_b^i = \langle i_3, i_4, i_1 \rangle$ 。

(4) 基于谓词相似度对图像答案排序。谓词相似度指上文中计算谓词和边的 SimCSE 相似度。按照谓词相似度从大到小排序。例如图 6 所示, 次要图像答案有多个, 根据谓词相似度排序可以获得 $E_b^i = \langle i_3, i_1, i_4 \rangle$ 。

利用上述方法可以获得多模态问题答案, 以图 6 为例, $E_{\text{MM}} = \langle i_{d2}, i_2, i_3, i_1, i_4 \rangle$ 。

4) 算法描述。为了清楚以上流程, 给出了相应的算法描述。如算法 1 所示。

算法 1 路径选择算法。

```
输入: TopicEntity, //主题实体
P, //谓词
IMKG //计算机领域多模态知识图谱
输出: Emm //多模态答案
Begin:
1. p = pre[0] //初始谓词为集合的第一个元素
2. do {
3. R = getRelation(topicentity); //获取边集 R
4. if len(R) == 0; //判断是否有答案
5. exit(); //退出循环
6. for <t, r, e> in R; //取每一条边
7. if SimCSE(p, r) > 0
8. RCandidate.add(<t, r, e>);
9. RMax = getMaxRelation(<t, r, e>);
//获取相似度最大边
10. if len(RCandidate) == 0; //没有找到大于阈值的边
11. OriginalPath.add(RMax);
12. else;
13. OriginalPath.add(getPruning(RCandidate)); //剪枝
14. topicentity = OriginalPath.last.Taile; //更新主题实体
15. if len(pre) > 1 and p == pre[0]: //有两个谓词
```

```
16. p = pre[1];
17. else if len(pre) > 1 and p == pre[1]:
18. exit();
19. else if len(pre) == 1 and len(RCandidate) != 0:
20. exit();
21. } while( true) //直到找到候选路径为止
22. StanOriginalPath = standardization(OriginalPath); //标准化
23. Eq = StanOriginalPath.last; //找到问题答案
24. Ebi = getSimilarRankedImage(OriginalPath);
25. Eai = getSimilarPathRankedImage(OriginalPath);
27. EMM = Eq ∪ Eai ∪ Ebi;
```

END

算法 1 中 $getPruning()$ 方法是根据图像类型来确定答案路径。 $getSimilarRankedImage()$ 方法是获取图像并基于相似度排序。 $getSimilarPathRankedImage()$ 方法是获取图像并基于相似度和距离排序。第 15 - 第 16 行表示, 当谓词集合长度为 2 且当前谓词为第一个元素时, 将谓词更新为第二个元素。第 17 - 第 18 行表示当谓词长度为 2 且当前谓词已经是第二个元素, 则跳出循环。第 19 - 第 20 行表示当谓词长度为 1 且 RCandidate 不为空, 则跳出循环。

4 实验与结果分析

本文利用 PMKBQA 方法在 CSQA 数据集上进行实验, 利用用户满意度对图像答案进行评估, 实验表明 PMKBQA 方法可以给用户提供满意的图像。同时, 为了评估问答效果, 在 QALD 数据集上做了对比实验, 结果表明 PMKBQA 方法与基线模型相比, 在 F1 评估标准中, 效果有所提高。具体实验如下。

4.1 多模态知识图谱的构建

1) 获取图像关系。对从 Wikipedia 中获取的图像经过清洗, 去除 logo 图像、没有图像标题和由于网络环境以及反爬虫的影响下载失败的图像后, 共获得 800 幅图像。对这 800 幅图像的标题进行知识抽取的结果如表 5 所示。

表 5 对计算机领域进行图像关系抽取结果

方法	Total	Process	Right	P/%	R/%	F1/%
OpenIE	800	440	247	56.14	30.88	39.84
Stanford CoreNLP	800	358	358	100	44.75	61.83
OpenIE + Stanford CoreNLP	800	798	605	75.81	75.63	75.72

表 5 中 Total 代表需要处理的数据,Process 表示处理的数据数,Right 表示关系抽取正确的数据数, $P = \text{Right}/\text{Process}$, $R = \text{Right}/\text{Total}$, $F1 = 2 \times P \times R / (P + R)$ 。表 5 中对这 800 幅图像首先使用了 OpenIE 抽取图像关系,处理了 440 个,由于精确率和召回率都很低,导致 F1 值很低,仅为 39.84%。而利用 Stanford CoreNLP 进行关系抽取,发现召回率 R 很低,最后将二者结合起来抽取图像关系,获得了较好的 F1 指标。因此选择 OpenIE 和 Stanford CoreNLP 共同进行图像关系抽取。

利用 YOLOv5 对图像进行目标检测,训练 Wikipedia 图像,将类别设置为 Computer、Mouse、Keyboard、Person、Experiment result 五类。结果如表 6 所示。

表 6 目标检测结果

分类	P	R	mAP@ 0.5
Total	0.888	0.890	0.893
Computer	0.889	0.833	0.871
Mouse	0.884	0.899	0.888
Keyboard	0.905	0.903	0.910
Person	0.917	0.921	0.917
Experiment result	0.846	0.893	0.877

表 6 中对所有类型的目标检测结果,在阈值为 0.5 的基础上,可以获得超过 0.89 的平均精确度 (mAP@ 0.5),意味着大部分的图像可以识别准确,因此本文认为这是一个可以接受的效果。

获得 ImageR 后,利用 OCR 获取“image_Has Word”关系,利用图像的 URL 获取“image_Name”关系和“image_URL”关系,利用图像的标题,获取“image_Title”关系,最终的 IMKG 中共有 11 类关系,2 096 个图像三元组。

2) 评估多模态知识图谱。构建多模态知识图谱主要评估 CSO 实体和图像之间的关系是否正确。利用用户满意度来对图像关系进行评估。用户满意度是本文提出的评估指标,反映的是用户对结果的满意程度。

$$S_{\text{satisfaction}} = \frac{\sum_{q \in Q} \sum_{i \in I_q} \text{Core}(q, i)}{\sum_{q \in Q} |I_q|} \tag{10}$$

用户满意度的计算式如式(10)所示,其中 $S_{\text{satisfaction}}$ 是用户答案满意度, Q 是 CSO 实体, I_q 是与 q 相关的图像, $|I_q|$ 表示图像个数。 $\text{Core}(q, i)$ 计算每幅图像和实体之间的满意度,如果用户认为符合条件则记为 1,否

则为 0。式(10)表示将每个与 q 相关的图像进行打分,取平均分作为最终评分。图 7 给出了计算示例。


Q	computer vision(C_V)	Artificial intelligence(A_I)
I		
	$\text{Core}(C_V, I_{C_V}) = \frac{1+1+0+0}{4} = 0.5$	$\text{Core}(A_I, I_{A_I}) = \frac{1+1+1+0}{4} = 0.75$
$\text{Core}(Q, I) = \frac{1+1+0+0+1+1+1+0}{8} = 0.625$		
$\times: 0 \quad \checkmark: 1$		

图 7 分数计算示例

图 7 中展示了对单个数据和一组数据打分的方式, $\text{Core}(C_V, I_{C_V})$ 表示对 C_V 的图像进行打分,而 $\text{Core}(Q, I)$ 是对这组数据全部进行打分。

为了评估图像关系是否正确,随机抽取出 10 组图像,每组 5 幅,分给计算机专业的 10 个用户,让他们使用用户满意度进行评估。如果用户认为图像和 CSO 实体之间的关系是正确的,则打分为 1,否则为 0。利用式(11)对每组分数计算。

$$a_{\text{veSatisfaction}} = \frac{\sum_{i=1}^n S_{\text{satisfaction}_i}}{n} \tag{11}$$

式中: $a_{\text{veSatisfaction}}$ 是用户平均满意度, n 是用户个数, i 表示第 i 个用户。式(11)表示,对于每组图像,让 n 个用户分别对其计算用户满意度,取每组图像的平均满意度作为该组图像的最终用户满意度。结果如图 8 所示,其中 Group 表示组别。




图 8 IMKG 评估结果

图 8 展示了对 IMKG 进行评估的结果,对图像关系的平均满意度达到了 80% 以上,本文认为这是一个可以接受的结果。

3) 构建知识图谱方法适用性评估。为了评估构建 IMKG 的方法可以迁移到其他领域,利用 QALD3 数据集进行评估。对 QALD3 数据集利用本文提出的主题实体识别方法抽取每个问题中的主题实体,共 100 个,对这 100 个主题实体到 Wikipedia 中获取页面,并在页面中获取图像、图像标题和图像 URL。由于获取的图像内容非常丰富,而人物图像较多,所以只选择人物图像作为图像源,以“Photo by”“wife”“son”这三类关系作为图像关系。

首先利用 Faster_RCNN 对所有的图像进行目标检测,选取所有“人物”图像。之后对所有“人物”图像进行清洗,去除所有 logo 图像、没有图像标题及由于网络环境以及反爬虫的影响下载失败的图像后,共获得 1 180 幅图像。然后利用本文方法将 OpenIE 和 Stanford CoreNLP 结合起来抽取图像关系,结果如表 7 所示。

表 7 QALD3 数据集图像关系抽取

方法	Total	Process	Right	P/%	R/%	F1/%
Faster_RCNN	4 996	1 180	—	—	—	—
OpenIE	1 180	778	358	46.02	30.34	36.57
StanfordCoreNLP	1 180	380	380	100	32.20	48.71
OpenIE + Stanford CoreNLP	1 180	1 158	738	63.73	62.54	63.13

综上所述,共获得了 738 个图像三元组。可见构建多模态知识图谱的方法可以从计算机领域迁移到公共领域。

4.2 主题实体识别评估

因为主题实体直接从问题三元组中获得,所以主题实体的质量由问题三元组决定。除了在 CSQA 数据集上进行实验之外,还需要在公开数据集上进行对比实验,来评估生成问题三元组的方法,选择 QALD3 进行对比实验。

利用本文提出的生成问题三元组方法对 QALD 和 CSQA 数据集进行处理,获得的结果如表 8 所示。精确度 $P = Right/Process$,其中:Right 是根据 QALD 数据集给出的 key 值相比较获得的,Process 表示处理的数据数。

表 8 知识抽取结果

方法	数据集	P/%
PMKBQA	CSQA	96.50
PMKBQA	QALD-3	65.00
FactQA ^[15]	QALD-3	62.24

利用本文提出的生成问题三元组的方法在 CSQA 数据集中进行实验,结果表明精确度在 96% 以上,且在 QALD-3 数据集上,精确度比 Zhang 等^[15]提出的基于规则生成问题三元组的方法的精确度要高,证明该方法有效。

获得问题三元组之后,从三元组中抽取主题实体,获得的结果如表 9 所示。

表 9 主题实体识别结果

方法	数据集	Total	Right	P/%
TagMe	CSQA	200	165	82.50
PMKBQA	CSQA	200	193	96.50

在 CSQA 数据集中利用问题三元组抽取主题实体的精确率为 96.5%,比直接利用 TagMe^[28]对 CSQA 数据集进行识别,得到的精确率要高得多,表明该方法有效。

4.3 问题答案路径生成的阈值选择

在获取答案路径时,需要通过设置相似度阈值来进行路径选择,为了确定阈值进行不同阈值的对比实验。

在 CSQA 数据集上,随机选择 50 个问题作为一个批次,共生成三个批次,将这三个批次的结果的平均值作为实验结果,如图 9 所示。




图 9 不同相似度阈值的效果

可以发现,随着阈值的增大,召回率逐渐降低,而准确率逐渐升高,这是因为当阈值很小时,可以得到多个问题答案,可能包含多个错误的答案,这导致了准确率很低,但是召回率很高,随着阈值的增大,使得获得的问题答案数量减少,因此准确率升高,召回率降低。因此选择 F1 值最高的作为阈值,即 0.5。

4.4 问答效果评估

1) 问题答案评估。在公开数据集上对问答效果

进行评估,表 10 展示了利用 DBpedia 作为背景知识库,PMKBQA 方法与其他基线方法在 QALD3 数据集上的对比结果。表 10 中 Total 表示问题数,Processed 表示给出的答案数。

表 10 QALD 数据集上实验结果

方法	Total	Processed	Right	P/%	R/%	F1/%
PMKBQA	99	42	29	69.05	29.30	41.14
Intui2 ^[32]	99	99	28	28.28	28.28	28.28
SWIP ^[32]	99	21	15	71.43	15.15	25.00

表 10 结果表明,PMKBQA 方法在 F1 评估指标上,优于 Intui2 和 SWIP,说明 PMKBQA 方法有效,可以给用户返回正确的问题答案。

为了评估计算机领域中获取问题答案的效果,在 CSQA 数据集上利用 IMKG 作为背景知识库,利用 PMKBQA 方法进行实验,获得的结果如表 11 所示。

表 11 CSQA 的结果

All_R	Total	Process	Right	P/%	R/%	F1/%
157	200	162	112	69.14	71.34	70.22
157	200	172	122	70.93	77.71	74.16

$P = \text{Right}/\text{Process}$, $R = \text{Right}/\text{All_R}$, $F1 = 2 \times P \times R/(P + R)$ 。其中:ALL_R 是问题集中去除没有答案的问题之后,共有 157 个问题有正确答案,Process 表示处理问题数,Right 是利用 PMKBQA 方法可以获得正确答案的问题数。

表 11 中第一行是没有利用图像类型进行消歧的结果,第二行是利用图像类型进行消歧的结果,结果表明,利用图像类型,可以有效地将 F1 提升 3.94 百分点,认为利用图像进行消歧是有效的。

对表 11 中的结果进行分析,发现没有处理和回答错误的问题,大部分是 IMKG 中没有答案。例如:basic_emotions 实体的相关图像没有 has_word 属性,也就不能获得准确答案。还有一部分问题回答错误是因为主题实体没有对应的图像,所以这部分问题没有办法回答,但是如果该节点有与其他节点的关系,那么会选择 一个与谓词相似度最大的关系进行匹配,会出现答案错误的情况。整体 F1 达到了 74% 以上,本文认为这是一个可以接受的结果。

2) 图像答案评估。为了对图像答案进行评价,从所有问题中随机抽取每个批次数量为 20 的 10 个批次的问题,对每个批次的问题进行回答,得到所有的图像答案。将这 10 个批次的问题交给 10 个用户来打分,利用平均用户满意度来进行评估。得到如图 10 所示的结果。




图 10 对图像答案进行评估

图 10 中对于图像答案的平均满意度达到了 80% 以上,表明大部分的用户对于图像答案还是满意的,本文认为这个结果是可以接受的,表明本文方法可以满足大部分人的需求。

3) 问答结果展示。图 11 给出了问题结果展示,多模态答案包括问题答案、主要图像问题和次要图像问题。对于 Q1,该问题经过一跳就可以获得答案,所以在对其一跳边进行相似度计算,可以在 IMKG 中与 AI 有关的所有节点,并根据阈值和相似度得到问题答案为 Computer vision、Robotics、Data mining 等,并且将所有与问题答案有关的图像关系抽取出来,找到 image_IsA 和 image_beUsedto 两种关系,将其尾实体作为主要图像答案。主题实体相关的图像关系为 image_IsA,将其尾实体作为次要图像答案。

Q1:	What are the applications of Artificial Intelligence ?
问题答案	Computer vision, Robotics, Data mining等
主要图像答案	image_BeUsedTo: image_IsA:
次要图像答案	image_IsA:
Q2:	What is Antivirus software used for?
问题答案	Antivirus software_4
主要图像答案	image_BeUsedTo:
次要图像答案	image_DevelopedBy:

图 11 对 CSQA 的回答结果

对于 Q2 通过相似度可以获得 anti-malware 实体的 image_BeUsedTo 关系,将其尾实体作为问题答案。主要图像答案则应为问题答案的所有属性,即 image_Name,image_HasWord 和 image_Title 的相应尾实体。次要图像答案应为与 anti-malware 有关的其他图像。

5 结 语

本文基于 CSO 本体构建多模态知识图谱和多模态问题集。为了回答多模态问题,提出 PMKBQA 方法,通过寻找答案路径可以有效地获得问题答案和图像答案。在公共领域数据集中进行对比实验,实验结果在 F1 评估指标上有了提升,表明本文方法可以有效地迁移到其他领域中。

PMKBQA 方法为基于知识图谱的智能问答机器人、基于知识图谱的搜索等应用领域提供了新的思路。

本文利用逐跳寻找路径可以有效地获得问题答案,但是在剪枝方面仍存在局限性,仅仅是依靠问题中的实体节点的类型代表答案的类型,存在一定的误差。在以后的工作中,将会在路径选择方法中,加入实体和图像的语义信息,通过这些语义筛选候选路径来提高剪枝的准确性。

参 考 文 献

- [1] Yu J, Zhu Z H, Wang Y J, et al. Cross-modal knowledge reasoning for knowledge-based visual question answering [J]. Pattern Recognition, 2020, 108: 107563.
- [2] Marino K, Rastegari M, Farhadi A, et al. OK-VQA: A visual question answering benchmark requiring external knowledge [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 3195 – 3204.
- [3] Wang P, Wu Q, Shen C H, et al. FVQA: Fact-based visual question answering [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 40 (10): 2413 – 2427.
- [4] Kannan A V, Fradkin D, Akrotirianakis I, et al. Multimodal knowledge graph for deep learning papers and code [C]//29th ACM International Conference on Information & Knowledge Management, 2020: 3417 – 3420.
- [5] Li H D, Wang Y F, Melo G D, et al. Multimodal question answering over structured data with ambiguous entities [C]//26th International Conference on World Wide Web Companion, 2017: 79 – 88.
- [6] Salatino A, Thanapalasingam T, Mannocci A, et al. The computer science ontology: A large-scale taxonomy of research areas [C]//International Semantic Web Conference, 2018: 187 – 205.
- [7] Liu A, Lu Z M, Xu N, et al. Multi-type decision fusion network for visual Q&A [J]. Image and Vision Computing, 2021, 115: 104281.
- [8] Dai J X, Ma L W, Fu D M, et al. Construction of visual question and answering system based on knowledge graph for specific objects [C]//Chinese Intelligent Systems Confer-

- ence, 2022: 751 – 759.
- [9] Zhu F B, Lei W Q, Huang Y C, et al. TAT-QA: A question answering benchmark on a hybrid of tabular and textual content in finance [EB]. arXiv: 2105.07624, 2021.
- [10] Li A H, Ng P, Xu P, et al. Dual reader-parser on hybrid textual and tabular evidence for open domain question answering [EB]. arXiv: 2108.02866, 2021.
- [11] Jiao J, Wang S J, Zhang X W, et al. gMatch: Knowledge base question answering via semantic matching [J]. Knowledge-Based Systems, 2021, 228: 107270.
- [12] Bakhshi M, Nematbakhsh M, Mohsenzadeh M, et al. SParseQA: Sequential word reordering and parsing for answering complex natural language questions over knowledge graphs [J]. Knowledge-Based Systems, 2022, 235: 107626.
- [13] Shin S, Lee K. Processing knowledge graph-based complex questions through question decomposition and recomposition [J]. Information Sciences, 2020, 523: 234 – 244.
- [14] Aditya S, Yang Y Z, Baral C. Integrating knowledge and reasoning in image understanding [C]//28th International Joint Conference on Artificial Intelligence, 2019: 6252 – 6259.
- [15] Zhang X M, Meng M, Sun X L, et al. FactQA: Question answering over domain knowledge graph based on two-level query expansion [J]. Data Technologies and Applications, 2020, 54: 2514 – 2548.
- [16] Shin S J, Jin X G, Jung J, et al. Predicate constraints based question answering over knowledge graph [J]. Information Processing & Management, 2019, 56 (3): 445 – 462.
- [17] Garderes F, Ziaeeafard M, Abeloos B, et al. Conceptbert: Concept-aware representation for visual question answering [C]//Conference on Empirical Methods in Natural Language Processing: Findings, 2020: 489 – 498.
- [18] Bai L Y, Yu W T, Chen M Z, et al. Multi-hop reasoning over paths in temporal knowledge graphs using reinforcement learning [J]. Applied Soft Computing, 2021, 103: 107144.
- [19] Zheng W F, Yin L R, Chen X B, et al. Knowledge base graph embedding module design for Visual question answering model [J]. Pattern Recognition, 2021, 120: 108153.
- [20] Li G H, Wang X, Zhu W. Boosting visual question answering with context-aware knowledge aggregation [C]//28th ACM International Conference on Multimedia, 2020: 1227 – 1235.
- [21] Shah S, Mishra A, Yadati N, et al. KVQA: Knowledge-aware visual question answering [C]//AAAI Conference on Artificial Intelligence, 2019: 8876 – 8884.
- [22] Zhan X L, Huang Y, Dong X, et al. PathReasoner: Explainable reasoning paths for commonsense question answering [J]. Knowledge-Based Systems, 2022, 235: 107612.

- [18] Keetha N V, Babu P, Annavarapu C. U-Det: A modified U-Net architecture with bidirectional feature network for lung nodule segmentation[EB]. arXiv:2003.09293,2020.
- [19] Zhang H, Zu K, Lu J, et al. EPSANet: An efficient pyramid squeeze attention block on convolutional neural network[EB]. arXiv:2105.14447,2021.
- [20] Gu R, Wang G T, Song T, et al. CA-Net: Comprehensive attention convolutional neural networks for explainable medical image segmentation[J]. IEEE Transactions on Medical Imaging,2021,40(2):699–711.
- [21] Woo S, Park J, Lee J Y, et al. CBAM: Convolutional Block Attention Module[EB]. arXiv:1807.06521,2018.
- [22] Han F F, Zhang G P, Wang H F, et al. A texture feature analysis for diagnosis of pulmonary nodules using LIDC-IDRI database[C]//2013 IEEE International Conference on Medical Imaging Physics and Engineering,2013.
- [23] Mukherjee S, Huang X J, Bhagalia R R. Lung nodule segmentation using deep learned prior based graph cut[C]//2017 IEEE 14th International Symposium on Biomedical Imaging (ISBI 2017),2017.
- [24] Jain S, Indora S, Atal D K. Lung nodule segmentation using salp shuffled shepherd optimization algorithm-based generative adversarial network[J]. Computers in Biology and Medicine,2021,137:104811.
- [25] Maqsood M, Yasmin S, Mehmood I, et al. An efficient DA-Net architecture for lung nodule segmentation[J]. Mathematics,2021,9(13):1457.
- [30] Marszaek-Kowalewska K, Zaretskaya A, Souek M. Stanford typed dependencies: Slavic languages application[C]//International Conference on Natural Language Processing,2014:151–163.
- [31] Gao T Y, Yao X C, Chen D Q. SimCSE: Simple contrastive learning of sentence embeddings[EB]. arXiv:2104.08821,2021.
- [32] Cimiano P, Lopez V, Unger C, et al. Multilingual question answering over linked data(QALD-3): Lab overview[C]//International Conference of the Cross-Language Evaluation Forum for European Languages,2013:321–332.

(上接第 216 页)

- [18] Li X R, Lan W Y, Dong J F, et al. Adding Chinese captions to images[C]//ACM on International Conference on Multimedia Retrieval,2016:271–275.
- [19] Wu J H, Zheng H, Zhao B, et al. AI challenger: A large-scale dataset for going deeper in image understanding[EB]. arXiv:1711.06475,2017.
- [20] 刘泽宇,马龙龙,吴健,等. 基于多模态神经网络的图像中文摘要生成方法[J]. 中文信息学报,2017,31(6):162–171.
- [21] 郭淑涛,赵德新. 一种基于深度学习的中文图像描述模型[J]. 天津理工大学学报,2020,36(3):30–35.
- [22] 邓珍荣,张永林,杨睿,等. 结合全局和局部特征的 BiG-RU-RA 图像中文描述模型[J]. 计算机辅助设计与图形学学报,2021,33(1):49–58.
- [23] Zhu S Y, Ng I, Chen Z. Causal discovery with reinforcement learning[EB]. arXiv:1906.04477,2019.
- [24] Chen C, Mu S, Xiao W P, et al. Improving image captioning with conditional generative adversarial nets[C]//33rd AAAI Conference on Artificial Intelligence,2019:8142–8150.
- [25] Papineni K, Roukos S, Ward T, et al. BLEU: A method for automatic evaluation of machine translation[C]//40th Annual meeting of the Association for Computational Linguistics,2002:311–318.
- [26] Lin C Y. ROUGE: A package for automatic evaluation of summaries[C]//42nd Annual Meeting of the Association for Computational Linguistics,2004:74–81.
- [27] Vedantam R, Zitnick C L, Parikh D. CIDEr: Consensus-based image description evaluation[C]//IEEE Conference on Computer Vision and Pattern Recognition,2015:4566–4575.
- [28] Robertson S. Understanding inverse document frequency: On the oretical arguments for IDF[J]. Journal of Documentation,2004,60(5):503–520.

(上接第 200 页)

- [23] Li X P, Wu B, Song J K, et al. Text-instance graph: Exploring the relational semantics for text-based visual question answering[J]. Pattern Recognition,2021,124:108455.
- [24] Wu Y R, Ma Y T, Wan S H. Multi-scale relation reasoning for multi-modal visual question answering[J]. Signal Processing: Image Communication,2021,96:116319.
- [25] YOLOv5[EB/OL]. [2021–10–20]. <https://github.com/ultralytics/yolov5/blob/master/CITATION/cff>.
- [26] Stanovsky G, Dagan I. Open ie as an intermediate structure for semantic tasks[C]//53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing,2015:303–308.
- [27] Du Y, Li C, Guo R, et al. PP-OCRv2: Bag of tricks for ultra lightweight OCR system[EB]. arXiv:2109.03144,2021.
- [28] Ferragina P, Scaiella U. Tagme: On-the-fly annotation of short text fragments[C]//19th ACM International Conference on Information and Knowledge Management,2010:1625–1628.
- [29] Manning C D, Surdeanu M, Bauer J, et al. The Stanford CoreNLP natural language processing toolkit[C]//52nd An-