

改进检索增强与 LLM 思维链维修策略生成

贺梓然 江 波 王晓龙

(中国电子科技集团公司第三十二研究所 上海 201808)

摘 要 针对高级装备维修场景下人工方式成本高、准确度依赖人员素质、无法有效利用历史维修经验等问题,提出一种改进检索增强与大语言模型(Large Language Models, LLM)思维链维修策略生成算法。即首先引入意图识别模块以优化处理路径;其次引入分层路由机制,通过关键因素进行多层分类;再次融合多查询检索器以提升检索效果,引入上下文压缩模块以减少冗余信息,避免注意力干扰;最终通过思维链推理方法,引导大语言模型逐步生成精细化维修策略。在高级装备故障诊断与维修决策领域,以典型航空飞行器维修决策作为实验以及应用验证场景,采用提出的高效维修策略生成算法,显著提升了高级装备维修策略生成准确性与时效性。

关键词 维修策略生成 大语言模型 改进检索增强生成 思维链推理

中图分类号 TP391

文献标志码 A

DOI:10.3969/j.issn.1000-386x.2025.03.001

IMPROVED RETRIEVAL-AUGMENTED AND LLM OF CHAIN-OF-THOUGHT MAINTENANCE STRATEGY GENERATION

He Ziran Jiang Bo Wang Xiaolong

(The 32nd Research Institute of China Electronics Technology Group Corporation, Shanghai 201808, China)

Abstract To address the issues of high costs in manual methods, accuracy dependence on personnel quality, and ineffective utilization of historical maintenance experience in advanced equipment maintenance scenarios, an improved retrieval-augmented and LLM chain-of-thought maintenance strategy generation algorithm is proposed. This algorithm introduced an intent recognition module to optimize processing paths. A hierarchical routing mechanism was incorporated to enable multi-layer classification based on key factors. A multi-query retriever was integrated to enhance retrieval effectiveness, and a context compression module was included to reduce redundant information and avoid attention interference. A chain-of-thought reasoning method guided the large language model in progressively generating refined maintenance strategies. In the field of advanced equipment fault diagnosis and maintenance decision-making, this efficient maintenance strategy generation algorithm was validated through experiments and applications in typical aircraft maintenance decision scenarios, demonstrating significant improvements in both the accuracy and timeliness of maintenance strategy generation for advanced equipment.

Keywords Maintenance strategy generation Large language models Improved retrieval-augmented generation (RAG) Chain-of-thought reasoning

0 引 言

高级装备故障诊断与维修决策是高级装备运行系统中必不可少的关键环节,直接影响到高级装备运行

安全性和运营效率。高级装备系统结构复杂、类型多样,其维护过程涉及大规模技术手册知识理解与历史维修数据整合与隐式耦合关系关联判断,传统人工决策方法难以迅速准确应对高级装备维护需求,且人工成本居高不下^[1-3]。

近年来,LLM^[4]如 GPT-3^[5]、BERT^[6]等在自然语言处理任务中表现出卓越理解与生成能力。但 LLM 在处理高度专业化装备维护与检修任务时依然面临显著挑战。首先,大规模语言模型训练数据多为通用语料,在精细化行业特定知识领域表现不足。其次在缺乏上下文以及可信知识支撑时模型可能生成虚假或无关输出,即“幻觉”现象,难以直接应用于高级装备维修高风险场景。有监督微调等大模型领域化方法难以快速适应行业领域知识更新且依赖于静态知识库,不适用于动态变化的复杂维修环境与需求。

检索增强生成^[7](Retrieval-Augmented Generation, RAG)大模型推理框架通过结合检索与生成的优势,为 LLM 提供外部知识支持。基础 RAG 框架将输入文本与外部知识库进行检索,然后将检索结果作为上下文输入到 LLM 中,从而生成更准确可信的答案。RAG 一定程度上能提高大模型输出准确性和可靠性,但朴素 RAG 框架对于高级装备维护场景仍存在精度不足和难以整合多源数据的缺陷。

针对上述不足,本文提出改进检索增强与 LLM 思维链维修策略生成算法,应用于高级装备故障诊断与维修决策领域,以航空飞行器维修策略生成作为实验以及应用验证对象。本文首先引入意图识别层对输入故障进行分类以选择最优处理路径,其次引入分层路由机制依据复杂维修历史数据关键因素进行多层分类,融合多查询检索器对多源信息进行融合检索召回以优化检索结果,再次引入上下文压缩层去除冗余信息,避免计算资源过度消耗以及注意力干扰,最后由思维链引导大语言模型分步生成精细化维修策略。

本文的主要贡献包括:1) 提出一种改进检索增强与 LLM 思维链维修策略生成算法,用于高级装备故障诊断与维修策略生成;2) 针对装备检维修场景高时效性及领域准确性要求,提出一套检索增强生成改进机制,显著提升在复杂场景中的维修策略生成精度。本研究为高级装备故障诊断与维修决策提供了一种维修策略生成算法,并验证了其在高风险、专业化场景中的准确性和高效性。

1 相关工作

高级装备维修过程中存在装备型号种类繁多、维修知识隐形关联复杂、知识可溯源程度低、知识可视化程度低、知识智能化复用程度低以及即时性要求高等诸多挑战。现有维修排故决策方法大多以降低预期修复成本为目标,采用启发式方法生成排故策略。钟珂

珂等^[8]提出增强现实与数字孪生混合驱动的航天高级装备维修辅助技术,利用数字孪生模型进行故障辅助诊断与维修流程诱导;刘宝鼎等^[9]提出了基于贝叶斯网络强化学习的高级装备维修排故策略生成方法,将维修排故决策问题转化为强化学习问题。上述方式存在知识更新滞后和灵活性缺失等不足,无法适应实际复杂环境中的设备和条件变化。

大语言模型(LLM)在自然语言处理中的出色表现为解决上述问题带来新思路。尽管如此,LLM 能力取决于预训练过程,训练数据的有限必然导致 LLM 原生知识无法覆盖到各类垂直领域中。LLM 在处理复杂装备维修任务时仍面临挑战,主要表现为通用语料训练数据在行业特定知识领域适配性欠缺、生成幻觉等。为改善上述问题,检索增强生成通过结合检索与生成成为 LLM 提供外部知识支持,用于提高语言模型效果和准确性^[10]。朴素 RAG 方法结合了两种主要 NLP 方法:检索(Retrieval)和生成(Generation)为 LLM 提供外部知识源以弥补 LLM“幻觉”现象。其中 HyDE(Hypothetical Document Embeddings)^[11]方法通过结合检索和生成过程动态集成多步推理,但其仍面临固定推理路径灵活性不足、计算资源消耗较大影响实用性的问题。LangChain^[12]提供了一种模块化工程路径,结合外部工具(如 API、数据库等)与 LLM 推理,但其模块间集成不够紧密导致多任务处理响应速度慢且准确率低。在高级装备检维修复杂场景中,传统 RAG 方法在数据源多样性、信息稀疏性、语义模糊性、复杂查询要求等因素下依然难以达到高召回率和高精度。

为进一步提升推理能力,思维链(Chain of Thought, CoT)^[13]方法近年来受到重视,借助逐步推理提高 LLM 面向复杂任务的表现。Wei 等^[14]首次提出思维链提示(Few-shot CoT),通过手动提供自然语言形式推理示例引入不同类型的逐步中间推理过程来扩展上下文学习,允许 LLM 模仿并生成推理路径。零样本思维链(Zero-shot CoT)^[15]通过特定提示文本激发模型在缺乏示例的情况下生成推理链条;自动思维链(Auto CoT)^[16]利用零样本生成推理链结合示例选择策略通过少样本学习方法进一步生成推理链条,为推理链构建提供了更大的灵活性和效率。半自动思维链(Semi-Auto CoT)^[17]融合手动与自动构建优势,引入人类对齐信号和示范选择策略,减少手动标记工作量同时增强推理能力及稳定性。

2 改进检索增强与 LLM 思维链维修策略生成

传统高级装备维修方式通常由人工对设备状态观察总结后依据故障处理手册或维修手册等内容,结合个人经验进行故障判断以及维修策略总结。为使大模型维修策略生成最大程度模拟还原标准装备检修过程,本文将输入定义为装备故障现象描述文本,输出定义为对应维修策略文本。

本节对改进检索增强与 LLM 思维链维修策略生成算法进行详细描述。本算法整体框架如图 1 所示。




图 1 改进检索增强与 LLM 思维链维修策略生成算法

2.1 改进的检索增强结构

首先引入意图分类层,具体在 BERT 架构中文嵌入模型基础上增加一个汇聚层,以 Attention Pooling 方式汇聚输出特征向量,同时增加一个 MLP 作为输出模块,将特征向量映射到不同意图类别的置信度。为防止过拟合冻结预训练参数,仅训练 Attention Pooling 层和 MLP 层。基于故障数据集进行问题类别构造,同时利用大语言模型随机生成高级装备领域不涉及故障检修的问题以及其他领域的开放性问题,以涉及装备维修数据作为正样本,不涉及数据则作为负样本,在该模型上进行微调以提高分类表现,从而将正负类型查询引导到对应处理管道。意图识别层在复杂查询输入场景中可扩展为多分类任务,进行多管道并行处理。意图识别作为前序处理层对故障现象文本输入进行粗分类以选择合适检索和生成路径,同时减少不必要的计算开销,提升策略生成流畅度。

面向装备检修问题,相当一部分故障描述与关键字段强相关。例如在航天飞行器装备检修领域中

飞行器机型、检修指导手册章节号为关键字段。因此本文以多分类任务模式在检索阶段设计一个分层路由层,结合关键因素特征进行逐层检索。

在该多分类模型训练阶段,采用提示词嵌入方式将问题和指定类别进行关联,作为分类模型输入;在输出层添加一个 MLP 输出多类别置信度,通过设置合理阈值在确保相关检索召回率同时逐层缩小检索范围,以提高检索精度与速度。

在复杂情形下,语义搜索通常使用文本语义信息计算相似度,例如使用文本嵌入向量来表示文本语义信息,但对于领域外查询或语义特征较少的查询语句,语义搜索结果可能不够准确或相关^[18-19]。

为了提高搜索结果相关性,本文引入多查询检索器,以语义搜索结合关键词搜索捕获文本语义相似度以及关键词匹配程度,更全面地考虑文本相关性以召回潜在相关文本块,改善搜索质量。

在检索阶段引入字符级重复语料检测技术作为上下文压缩层。通过该层识别并剔除历史维修数据中高度相似或重复部分从而有效减少冗余信息传递,对模型输出无关字段信息进行剔除处理。这一过程通过上下文数据压缩有效减少无关信息干扰,进而提高检索精准度和针对性,减缓长上下文可能带来的注意力干扰以及资源过度消耗问题。

通过引入基于加权算法和 Embedding 模型作为 Re-rank 策略以实现候选结果生成后对相关度进行精确排序。首先利用 RRF (Reciprocal Rank Fusion) 算法^[20]将多个检索源结果进行加权组合,确保高质量候选结果获得更高排名,其次结合 BGE 模型^[21]对候选结果间语义关系进行建模,进一步提升排序准确性和相关性。重排序层通过多层次加权融合和深度语义建模充分考虑多源信息和语义联系,从大量候选结果中筛选出最符合需求的结果,同时显著提升系统响应质量与精度。

2.2 LLM 思维链推理生成

思维链提示层是本算法核心策略之一,旨在通过逐步推理引导大语言模型 (LLM) 实现更为准确、精细的维修策略生成。该层基于思维链 (Chain-of-Thought, CoT) 推理方法,要求模型在生成维修策略过程中进行多步推理,而非直接生成最终结果。

在该模块中,首先根据故障现象描述文本和改进检索增强阶段得出的相关信息构建思维链步骤,通过具体提示信息明确模型生成方向。例如在航天器维修场景中,思维链提示包括以下步骤:首先定位

故障关键部件或系统;下一步推理出可能故障原因;然后结合历史维修数据及相关手册确定维修办法。每一步均通过结构化提示明确给出,确保模型不会跳过关键推理步骤,从而生成符合标准流程的维修策略。

为了进一步提升思维链提示效果,本研究采用了动态调整的思维链提示策略。在模型生成过程中逐步对推理链条进行修正和优化,实时纠正可能存在的推理偏差。该机制通过分析模型生成中间结果与推理步骤进行比对,及时引导模型进入正确推理路径。思维链层能够强化推理过程的稳定性和可解释性,同时能够有效避免模型在复杂维修任务中的“幻觉”现象,确保输出的维修策略与实际需求高度一致。


此外,思维链提示层支持扩展多样化推理路径,针对不同类型故障和设备生成定制化维修策略,并在多种潜在推理路径间进行选择,根据任务需求和上下文信息动态调整推理策略。

3 实验与工程应用


3.1 数据处理

飞行器设备维修属于高级装备维修中的典型场景。因此本文将以飞行器维修场景作为实验主体。实验数据机型为波音 73N 和空客 320 的系统历史维修记录数据。为了高效提取数据中的信息,本文对原始检修数据字段重要性进行人工评估,选择机型、建单日期、描述、措施、章节号五个关键字段,其中描述、措施和章节号用于检索和模型决策参考,而机型和建单日期作为数据溯源和工程应用页面预览。

本文根据字段和数据属性,对噪声数据和无用数据进行过滤,结果如图 2 所示。完成数据清洗之后,对剩下的数据进行字符规范化,以获得结构化的干净数据并以 JSON 格式保存。



(a) 数据清洗统计



(b) 清洗项统计

图 2 数据统计

3.2 实验设置

3.2.1 模型基座选择

本文在综合考虑计算资源、任务适用性以及模型性能等多方面因素后,选用了 Qwen^[22] 和 ChatGLM^[23] 作为大模型的基础架构。Qwen 在多任务处理和扩展性方面表现出色,适合复杂的语言理解任务;而 Chat-GLM 在对话生成和自然语言理解上具备优异表现,能够支持多轮互动并适应多种应用场景。两种模型的详细参数和特性对比如表所示,以直观展示其在不同场景中的适用性和技术特性,如表 1 所示。

表 1 大模型选择及其细节

基座模型	包含模型	参数量 (<i>B</i>)	训练 Token 数 (<i>T</i>)	训练 最大长度 (<i>K</i>)
ChatGLM	ChatGLM/2/3 Base&Chat	6	1/1.4	2.32
Qwen	Qwen/2 Base&Chat	7/32/ 72/110	2.2/3	8/32

3.2.2 实验环境

本文实验在 Linux 环境下进行,基于 PyTorch 2.0.1 框架和 Python 3.11.9 编程语言,硬件平台为 NVIDIA A100 GPU,配备 40 GB 显存。此外为了进一步优化 GPU 的计算能力,实验环境中配置了 CUDA 和 cuDNN 加速库。

3.2.3 评价指标

为了评估模型输出的质量,本文选择语义相关性评估方法对模型对结果评估,如式(1)所示。

$$S = \frac{1}{n} \sum_{i=1}^n sim(q_{pred}^i, q_{ground}^i) \tag{1}$$

式中: q_{pred}^i 查询样本 i 的模型输出编码向量, q_{ground}^i 表示数据集中真实标签的编码向量。 $sim(,)$ 采用余弦相似

度进行度量。该指标衡量生成的答案与查询之间的相关性,分数越高,相关性越好。

为了评估模型的时效性,本文采用平均响应速度作为模型的评价指标。响应速度的评估主要涵盖了两个核心部分:检索速度和大模型输出速度。检索速度指的是系统从数据库或索引中获取相关信息所需的时间,而大模型输出速度则是指模型处理输入并生成响应所需的时间,计算如式(2)所示, t_i 表示单个样本的响应时间。

$$T_{\text{average}} = \frac{1}{n} \sum_{i=1}^n t_i$$

(2)

3.3 实验结果分析

本文实验以 Qwen2 和 ChatGLM3 两种大模型为底座,同时选择 HyDE 和 LangChain 作为 RAG 策略比较,采用语义相关性和平均响应速度两个指标进行评估,模型结果如表 2 所示。

表 2 实验结果			
模型	RAG 策略	语义相似度/%	平均响应速度/s
Qwen2	HyDE	89.7	4.28
	LangChain	89.4	4.06
	本文算法	90.3	4.12
ChatGLM3	HyDE	88.6	3.67
	LangChain	88.3	3.26
	本文算法	89.1	3.41

由实验结果可知,基于 Qwen2 的语义相似度优于基于 ChatGLM3 模型,而前者平均响应速度慢于后者。为了满足任务效果需求,本文选择基于 Qwen2 作为本算法的核心部件,支持维修策略生成。同时,对于不同的 RAG 策略,三种策略下的模型均能达到较高的语义相似度,但本文算法在两个模型上的语义相似度均优于其他策略,显示本文算法在语义匹配的准确性上具有一定的优势。在响应速度方面,基于 ChatGLM3 的模型整体优于基于 Qwen2 的模型,且不同 RAG 策略下平均响应速度均优于 Qwen2。

为了验证基于 RAG 检索时,不同检索结果对于任务的影响。本文分别选择 $TopN \in \{1,2,3\}$ 进行验证,其结果如图 3 所示。




图 3 不同 TopN 值对应的语义相似度和平均响应速度

实验结果表明,随着 TopN 值的增加,模型的语义相似度呈现上升趋势,Qwen2 和 ChatGLM3 在 TopN = 5 时的语义相似度分别为 91.6 和 90.5,表现最佳。然而,响应速度随着 TopN 增大而显著增加,Qwen2 的响应时间从 2.87 秒增至 8.65 秒,ChatGLM3 也表现出类似的趋势。整体来看,Qwen2 在语义相似度方面优于 ChatGLM3,但后者的响应速度更快,特别是在 TopN = 1 和 TopN = 3 时,平均响应时间为 1.63 秒和 3.41 秒。根据任务需求,若精度优先,Qwen2 在较大 TopN 下较为合适;若响应速度更为重要,则 ChatGLM3 是更好的选择。

3.4 工程应用验证

3.4.1 有效性验证

为验证所提出算法有效性,本文设计并实施了超过 200 次人机问答测试,旨在评估算法在真实场景中的响应准确性和可靠性。测试过程中,通过选择特定机型 320 并提出实际运维中可能遇到的复杂问题,例如“APU 启动失败”以及“机长测皮托管加温灯亮:左侧皮托管”等场景,模型能够基于输入问题精准解析其含义,并提供符合实际需求的故障诊断与维修策略,具体示例如图 4 所示。



图 4 模型问答准确性

该测试结果表明,模型具备识别关键问题、分析问题背景并快速输出有效解决方案的能力,展示了其在航空飞行器维修领域中的实用性和高效性。

3.4.2 可溯源性验证

为进一步验证模型的可溯源性,展示其在实际应用中的可靠性和可信度,系统设计了参考文件链接呈现方式。在搜索结果中模型提供明确回答,同时还包含与回答相关的参考文件或文献链接,使用户能够深入查阅原始信息来源,如图 5 所示。该设计有效保障用户对信息源的追溯,使答案可信度更高。



图 5 模型回答可靠性

4 结 语

本文针对高级装备维修场景中人工依赖、维修数据利用率低下等问题提出了一种改进检索增强与 LLM 思维链维修策略生成算法,通过引入意图识别、多层分类路由、多查询检索器改进现有检索增强生成框架,并结合思维链推理提供了一种高效自动化维修策略生成方法,提升了复杂装备故障诊断与维修决策准确性和时效性。

通过实验结果表明,本文算法在以下方面表现出显著优势:1) 在精确度方面优于传统 RAG 框架,有效处理多样数据和语义模糊问题,实现更高相关性的知识检索增强生成;2) 引入思维链推理提升了大语言模型在复杂任务中的逻辑推理能力,生成的维修策略在可操作性和准确性上优于现有方法。通过工程应用验证表明,本文算法具备较强适应性与可扩展性,能够适应动态变化的维修环境和高风险场景,为复杂装备故障维修决策提供有效依据。未来研究将致力于提升算法跨领域适应性和多源数据融合能力,进一步推动智能化维修技术发展与应用。

参 考 文 献

[1] Mofokeng T, Mativenga P T, Marnewick A. Analysis of aircraft maintenance processes and cost [J]. Procedia CIRP, 2020, 90: 467 – 472.

[2] 丁申虎,贾云献,马全跃. 复杂装备系统组合维修研究现

状综述 [J]. 兵器装备工程学报, 2018, 39 (9) : 117 – 121.

[3] Bulbul K G, Kasimbeyli R. Augmented Lagrangian based hybrid subgradient method for solving aircraft maintenance routing problem [J]. Computers & Operations Research, 2021, 132: 105294.

[4] Zhao W X, Zhou K, Li J, et al. A survey of large language models [EB]. arXiv:2303.18223, 2023.

[5] Radford A, Wu J, Child R, et al. Language models are unsupervised multitask learners [J]. OpenAI Blog, 2019, 1 (8) : 9.

[6] Devlin J. Bert: Pre-training of deep bidirectional transformers for language understanding [EB]. arXiv:1810.04805, 2018.

[7] Zhao P, Zhang H, Yu Q, et al. Retrieval-augmented generation for ai-generated content: A survey [EB]. arXiv:2402.19473, 2024.

[8] 钟珂珂,洪海波,宋倩,等. 增强现实与数字孪生混合驱动的航天复杂装备维修辅助技术研究 [J]. 军民两用技术与产品, 2023 (4) : 5 – 10.

[9] 刘宝鼎,于劲松,韩丹阳,等. 基于贝叶斯网络强化学习的复杂装备维修排故策略生成 [J]. 北京航空航天大学学报, 2022, 50 (4) : 1354 – 1364.

[10] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks [J]. Advances in Neural Information Processing Systems, 2020, 33: 9459 – 9474.

[11] Gao L, Ma X, Lin J, et al. Precise zero-shot dense retrieval without relevance labels [EB]. arXiv:2212.10496, 2022.

[12] Liu Y. LangChain: A toolchain for building, training, and deploying language models [EB/OL]. [2024-12-10]. <https://github.com/langchain-ai/langchain>.

[13] Chu Z, Chen J, Chen Q, et al. A survey of chain of thought reasoning: Advances, frontiers and future [EB]. arXiv:2309.15402, 2023.

[14] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models [J]. Advances in Neural Information Processing Systems, 2022, 35: 24824 – 24837.

[15] Kojima T, Gu S S, Reid M, et al. Large language models are zero-shot reasoners [J]. Advances in Neural Information Processing Systems, 2022, 35: 22199 – 22213.

[16] Zhang Z, Zhang A, Li M, et al. Automatic chain of thought prompting in large language models [EB]. arXiv:2210.03493, 2022.

[17] Shao Z, Gong Y, Shen Y, et al. Synthetic prompting: Generating chain-of-thought demonstrations for large language models [C] // International Conference on Machine Learning. PMLR, 2023: 30706 – 30775.

参 考 文 献

- [1] Ruff L, Vandermeulen R, Goernitz N, et al. Deep one-class classification[C]//35th International Conference on Machine Learning, 2018:4393–4402.
 - [2] Yi J, Yoon S. Patch SVDD: Patch-level SVDD for anomaly detection and segmentation[C]//Asian Conference on Computer Vision, 2020:375–390.
 - [3] Wang S, Wu L, Cui L, et al. Glancing at the patch: Anomaly localization with global and local feature comparison [C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021:254–263.
 - [4] Li C, Sohn K, Yoon J, et al. CutPaste: Self-Supervised learning for anomaly detection and localization [C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021:9659–9669.
 - [5] 李悦,嵇启春. 基于异常检测的尿沉渣图像分割[J]. 计算机应用与软件, 2017, 34(6): 212–216, 261.
 - [6] 夏裕建,孙涵. 监控视频异常检测与质量诊断[J]. 计算机应用与软件, 2016, 33(6): 163–167, 211.
 - [7] 柳月强,张建锋,祝麒麟,等. 基于时空相关性的多传感器数据异常检测[J]. 计算机应用与软件, 2020, 37(10): 85–90.
 - [8] Shi Y, Yang J, Qi Z. Unsupervised anomaly segmentation via deep feature reconstruction[J]. Neurocomputing, 2021, 424:9–22.
 - [9] Bergmann P, Fauser M, Sattlegger D, et al. Uninformed students: Student-teacher anomaly detection with discriminative latent embeddings[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020: 4183–4192.
 - [10] Wang G, Han S, Ding E, et al. Student-teacher feature pyramid matching for unsupervised anomaly detection [EB]. arXiv:2103.04257, 2021.
 - [11] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 39(4): 640–651.
 - [12] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation [C]//International Conference on Medical Image Computing and Computer-Assisted Intervention, 2015:234–241.
 - [13] 林志洁,郑秋岚,梁涌,等. 基于内卷 U-Net 的医学图像分割模型[J]. 计算机工程, 2022, 48(8): 180–186.
 - [14] Chen L, Papandreou G, Kokkinos I, et al. Semantic image segmentation with deep convolutional nets and fully connected CRFs[EB]. arXiv:1412.7062, 2014.
 - [15] Chen L, Papandreou G, Kokkinos I, et al. Deeplab: Semantic image segmentation with deep convolutional nets, Atrous convolution, and fully connected CRFs [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 40(4): 834–848.
 - [16] Chen L, Papandreou G, Schroff F, et al. Rethinking Atrous convolution for semantic image segmentation [EB]. arXiv: 1706.05587, 2017.
 - [17] Chen L, Zhu Y, Papandreou G, et al. Encoder-decoder with Atrous separable convolution for semantic image segmentation [C]//European Conference on Computer Vision, 2018:833–851.
 - [18] 史健锋,高治明,王阿川. 结合 ASPP 与改进 HRNet 的多尺度图像语义分割方法研究[J]. 液晶与显示, 2021, 36(11): 1497–1505.
 - [19] Bergmann P, Fauser M, Sattlegger D, et al. MVTec AD-A Comprehensive Real-World dataset for unsupervised anomaly detection [C]//2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019:9584–9592.
 - [20] Paszke A, Gross S, Massa F, et al. Pytorch: An imperative style, high-performance deep learning library [C]//33rd International Conference on Neural Information Processing Systems, 2019:8026–8037.
 - [21] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition [C]//2016 IEEE Conference on Computer Vision and Pattern Recognition, 2016:770–778.
- ~~~~~
- (上接第6页)
- [18] Wang J, Dong Y. Measurement of text similarity: A survey [J]. Information, 2020, 11(9): 421.
 - [19] Chandrasekaran D, Mago V. Evolution of semantic similarity-A survey[J]. ACM Computing Surveys (CSUR), 2021, 54(2): 1–37.
 - [20] Cormack G V, Clarke C L A, Buettcher S. Reciprocal rank fusion outperforms condorcet and individual rank learning methods [C]//Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval, 2009: 758–759.
 - [21] Chen J, Xiao S, Zhang P, et al. Bge m3-embedding: Multilingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation[EB]. arXiv: 2402.03216, 2024.
 - [22] Yang A, Yang B, Zhang B, et al. Qwen2. 5 technical report[EB]. arXiv: 2412.15115, 2024.
 - [23] GLM T, Zeng A, Xu B, et al. Chatglm: A family of large language models from glm-130b to glm-4 all tools [EB]. arXiv:2406.12793, 2024.