

知识库问答场景中大语言模型私有化研究与应用实践

丁 咚¹ 杨文昌²

¹(上海烟草集团有限责任公司 上海 200092)

²(上海卷烟厂 上海 200092)

摘 要 针对企业在知识库问答场景中对大语言模型私有化部署的迫切需求,以上海卷烟厂为实践案例,详细探讨了运用检索增强生成(RAG)技术构建本地化知识库的方法与流程。研究结合开源的 Qwen1.5-32B 大模型与 BAAI/BGE-large-zh-v1.5 词嵌入模型,并在模型选型时充分权衡算力限制与模型性能表现,介绍了具体的构建方案。实验结果表明,所提出的 RAG 方案能够有效提升信息检索与问答的准确性,且 INT4 量化能在显著降低显存占用的同时,对问答效果影响较小,为企业在垂直领域安全、高效地进行大语言模型私有化部署与应用提供了具有参考价值的技术方案与实践指导。

关键词 大语言模型 检索增强生成 知识库问答

中图分类号 TP3 **文献标志码** A **DOI**:10.3969/j.issn.1000-386x.2025.10.018

RESEARCH AND APPLICATION PRACTICE OF LARGE LANGUAGE MODEL PRIVATE DEPLOYMENT IN KNOWLEDGE BASE QUESTION ANSWERING SCENARIOS

Ding Dong¹ Yang Wenchang²

¹(Shanghai Tobacco Group Co., Ltd., Shanghai 200092, China)

²(Shanghai Cigarette Factory, Shanghai 200092, China)

Abstract To address the urgent need for private deployment of large language models (LLMs) in enterprise knowledge base question answering (KBQA) scenarios, this study presents a detailed exploration of utilizing retrieval-augmented generation (RAG) technology to build a localized knowledge base, using the Shanghai Cigarette Factory as a practical case study. The research integrated the open-source Qwen1.5-32B LLM with the BAAI/BGE-large-zh-v1.5 embedding model. A specific construction scheme was introduced, with model selection thoroughly considering both computational resource limitations and model performance. The practice validates the effectiveness of the RAG technique in significantly improving the accuracy of information retrieval within a specific domain knowledge base. INT4 quantization can significantly reduce video memory usage while having a minimal impact on question answering performance. This work offers a valuable technical scheme and practical guidance for the secure and efficient private deployment and application of LLMs in vertical industries.

Keywords Large language model Retrieval augmented generation Knowledge base question answering

0 引 言

自 2017 年 Google 提出 Transformer 架构以来,自然语言处理领域取得了突破性进展^[1]。以 ChatGPT 3.5^[2]、GPT-4o^[3] 等为代表的大语言模型(LLM)展现出卓越的语言理解与生成能力,正深刻变革着各行各

业。2024 年 3 月,总理政府工作报告中明确提出“开展‘人工智能+’行动”,预示着 LLM 在产业中的应用将进入加速期。

然而,企业在引入 LLM 技术时,普遍面临数据安全、隐私保护和业务合规的严峻挑战^[4]。将模型部署于公有云或使用外部 API 服务,可能导致企业核心数据泄露风险。因此,大语言模型的私有化部署成为保

障企业数据主权的必然选择。在众多企业应用场景中,知识库问答(KBQA)需求尤为突出,它旨在为员工或客户提供即时、准确的信息支持,是提升企业内部知识管理效率的关键环节。

直接使用通用大语言模型进行私有化部署,常因其缺乏特定领域的专业知识而导致回答效果不佳,即存在“幻觉”现象^[5],这凸显了通用模型与特定业务场景适配性的核心挑战。为解决该问题,传统的全量微调^[6](Full Fine-tuning)方法虽然能向模型注入领域知识,但其高昂的算力与时间成本令多数企业望而却步。检索增强生成^[7](Retrieval-Augmented Generation, RAG)技术为此提供了高效的解决方案。RAG 通过在生成答案前从外部知识库中检索相关信息,并将其作为上下文提供给 LLM,从而在不改变模型权重的情况下,显著提升回答的准确性和时效性。

本文以上海卷烟厂信息化支持系统的建设为实践背景,对基于 RAG 技术的私有化知识库问答系统进行深入研究与实现。本研究的核心贡献在于:1) 设计并验证了一套基于开源模型(Qwen1.5-32B 与 BAIE/BGE-large-zh-v1.5)的完整私有化 RAG 部署方案;2) 通过定量实验,系统性地评估了文本分块策略、词嵌入模型选择对检索性能的影响;3) 深入探究了模型量化(INT8 与 INT4)对系统回答质量、推理速度和硬件资源消耗的综合影响,为企业在成本和性能之间做出权衡提供了实证依据。

1 相关技术与研究现状

1.1 大语言模型与私有化部署

大语言模型通常含有数十亿乃至上万亿参数,其预训练过程需要海量的计算资源^[8]。为使模型适应特定领域,全量微调需消耗与预训练同等量级的资源,不适合大多数企业。以 LoRA 为代表的部分参数高效微调(Parameter-Efficient Fine-Tuning, PEFT)技术通过仅训练少量适配器参数来降低成本,但仍需要高质量的标注数据集和一定的训练周期^[9]。私有化部署将模型置于企业内部服务器,虽能从根本上解决数据安全问题,但也对企业的硬件设施和运维能力提出了要求。因此,如何在有限的资源下最大化模型效能,成为私有化部署研究的核心。

1.2 检索增强生成(RAG)

RAG 作为一种结合了信息检索与文本生成的技术框架,其工作流程通常分为检索和生成两个阶段。

在检索阶段,系统根据用户输入从知识库中召回最相关的文档片段;在生成阶段,这些文档片段与原始问题一同被送入 LLM,引导模型生成基于所提供知识的回答。RAG 与模型微调技术相比,RAG 不需要对大模型本身进行训练,而是通过提示词工程限制模型的输出来增强使用效果。如表 1 所示,相较于微调,RAG 在知识更新上更为敏捷,只需更新知识库即可,无需重新训练模型^[10]。同时,由于答案有据可循,RAG 有效缓解了 LLM 的“幻觉”问题,增强了回答的可解释性。目前,RAG 已成为提升 LLM 在知识密集型任务中表现的主流范式。

表 1 检索增强生成和模型微调的特点对比^[11]

特性	检索增强生成	模型微调
硬件要求	额外的向量数据库和向量模型资源需求	需满足模型调参 GPU 内存和算力需求,成本较高
灵活性	灵活性高,模型的更换不会对整个系统造成影响,可随时增加或更新知识	灵活性低,更换模型后需要重新训练,由于训练时间较长,更适合变化周期较长的知识内容
回复速度	当知识库内数据量较大时需额外检索时间	取决于显卡性能和模型大小

1.3 模型量化技术

为在资源受限的设备上部署大型模型,模型量化技术应运而生。该技术通过降低模型参数的数值精度,如从 32 位浮点数(FP32)映射到 16 位浮点数(FP16)、8 位整数(INT8)或 4 位整数(INT4),来压缩模型大小并加速计算^[12]。虽然理论上精度降低会带来性能损失,但 Dettmers 等的研究表明,对于 Transformer 架构,INT8 量化几乎可以实现无损性能,而更低的精度(如 INT4)也能在多数任务中保持可接受的性能水平,同时带来显著的效率提升^[13]。

2 系统架构与关键技术

2.1 系统整体架构

本研究构建的私有化知识库问答系统遵循经典的 RAG 架构,其整体工作流程如图 1 所示。系统部署于企业内网,确保所有数据处理和模型调用均在本地完成。用户通过前端应用界面提交问题后,请求被送至后端服务。后端首先对用户问题进行向量化处理,并利用该向量在预先构建好的 FAISS 向量数据库中进行相似性检索,召回最相关的知识片段。这些知识片段随后被整合进一个为特定业务场景设计的提示词模板

中,并与原始问题一同传递给本地部署的 Qwen1.5-32B 大语言模型。模型在理解上下文后生成回答,最终返回给前端展示给用户。为提升系统在特定业务场景下的适用性和准确性,本研究从知识库构建和提示词工程两个层面进行了定制和优化。




图 1 系统整体架构与工作流程

2.2 关键技术选型

系统的核心技术选型充分考虑了开源生态、性能表现及私有化部署的资源限制。大语言模型选用 Qwen1.5-32B 模型,该模型在中文理解和生成方面表现优异,且 32B 参数量在性能与私有化部署资源需求之间取得了较好平衡。词嵌入模型选用 BAAI/BGE-large-zh-v1.5 模型,该模型在中文语义表征任务中名列前茅,能有效捕捉文本间的语义相似性。向量数据库选用 FAISS^[14],该向量数据库为高效的相似性搜索库,支持大规模向量索引和快速检索。模型量化技术重点考察 INT8 和 INT4 量化对 Qwen1.5-32B 模型性能的影响。

2.3 知识库构建与 RAG 流程实现

知识库构建的数据源为上海卷烟厂信息技术科整理的软硬件系统常见问题和解决方法。文档经过清洗和预处理后,文本切分是关键步骤。本研究对比了不同切分策略,并根据企业 FAQ 文档的特点,最终采用效果更优的“问答对分块”方式,即将每个 FAQ 的问答对视为一个独立的文本块。这种基于业务数据形态的优化策略,能最大程度保留问题的意图与答案的直接对应关系。随后使用 BGE-large-zh-v1.5 模型将文本

块转换为 1 024 维向量,存储于 FAISS 索引中。

用户提问时,问题文本由 BGE-large-zh-v1.5 模型转换为查询向量。系统在 FAISS 索引中执行相似度搜索(如余弦相似度),召回最相关的 K 个问答对(本实践中 K 设置为 3)。这些问答对将被整合到定制化提示词模板中。

2.4 基于业务需求的提示词工程优化

为了使模型的回答更贴合企业 IT 支持的业务场景,我们设计了专门的提示词(Prompt)。该提示词不仅指导模型如何使用检索到的上下文,还通过角色扮演和格式要求来规范其输出,从而实现应用层面的模型优化。一个具体的示例如下:

```
{
  "model_mode": "completion",
  "prompts": [
    {
      "role": "user",
      "text": "使用 <QA> </QA> 标记中的问答对进行回答。

      <QA>
//此处为知识库检索输出
</QA>

      回答要求:
      - 你是一个耐心、友好、熟悉上海烟草集团及上海卷烟厂内部规章制度的运维人员,你能够为员工提供内部培训文档的查询和解释,回答员工关于信息类问题,包括但不限于软硬件问题,网络问题等政策、流程和规定的问题。
      - 选择其中一个或多个问答对进行回答。
      - 回答的内容应尽可能与 <QA> </QA> 中的内容一致。
      - 如果 <QA> </QA> 中无相关内容,你需要澄清。
      - 避免提及你是从 <QA> </QA> 获取的知识,只需要回复答案。
      - 请使用 Markdown 格式优化输出内容。
      Human: 如何更改邮箱密码?"
    }
  ]
}
```

该提示词通过明确的“回答要求”,引导 LLM 扮演“耐心、友好的运维人员”角色,确保回答的语气和风格符合业务需求。同时,要求其回答严格基于 <QA> 内容,并在信息不足时进行澄清,有效提升了回答的准确性和可靠性。要求使用 Markdown 格式输出,则优化了最终呈现给用户的可读性。这种定制化的提示词工程是提升模型业务适用性的关键环节。

3 实验设置与结果分析

3.1 实验环境与数据集

实验软件环境为 Ubuntu 20.04 LTS, Python 3.10, PyTorch 2.0.1, Ollama 0.1.32, Dify 0.6.0。具体的硬件资源配置如表 2 所示。

表 2 实验硬件资源配置

组件	具体型号/配置
CPU	Intel Xeon Gold 6330
GPU	NVIDIA A800 (80GB HBM2e)
内存	256 GB
存储	NVMe SSD 4TB
主板	双路 LGA 4189 服务器主板
网卡	Mellanox ConnectX-6 100GbE

数据集来源于“上海卷烟厂信息技术科整理的软硬件系统常见问题和解决方法”,共包含 357 个独立的问答对,覆盖账户密码、网络配置、软件使用、硬件故障等常见 IT 支持问题。从中随机抽取 50 个问题作为测试集 (Test Set),剩余 307 个问答对用于构建知识库。

评价指标包括:检索准确率 (Hit Rate@ K, 本实验关注 $K=1$ 和 $K=3$)、平均倒数排名 (Mean Reciprocal Rank, MRR) 用于评估检索模块性能^[15];生成回答的准确性、相关性和流畅性通过人工评估 (1-5 分制,5 分最高,由 20 位评估员打分后取平均值) 和具体案例分析进行评价;系统性能则关注每秒 Token 生成数 (Tokens/s) 和 GPU 显存占用 (GB)。

3.2 检索模块性能评估

首先,对不同文本分块方式^[16]进行比较。在 BGE-large-zh-v1.5 嵌入模型下,对比了“问答对分块”与“固定长度分块”(chunk_size = 256 tokens, chunk_overlap = 32 tokens)对检索性能的影响。结果如表 3 所示。

表 3 不同分块方式对检索准确率的影响

分块方式	Hit Rate@ 1	Hit Rate@ 3	MRR
问答对分块	90.9%	96.5%	0.928
固定长度分块	54.5%	68.2%	0.613

从表 3 可以看出,“问答对分块”策略在 Hit Rate@ 1、Hit Rate@ 3 以及 MRR 上均显著优于“固定长度分块”。这主要是因为问答对本身具有高度的语义完整性和问题导向性,更利于精确匹配用户查询。

其次,在“问答对分块”策略基础上,对比了 BAAL/BGE-large-zh-v1.5 与另一款常用的中文嵌入模

型 M3E-Base 的检索性能。结果如表 4 所示。

表 4 不同词嵌入模型对检索准确率的影响

词嵌入模型	Hit Rate@ 1	Hit Rate@ 3	MRR
BGE-large-zh-v1.5	90.9%	96.5%	0.928
M3E-Base	86.4%	93.1%	0.885

表 4 结果显示,BGE-large-zh-v1.5 在各项检索指标上均优于 M3E-Base,表明其在本知识库场景下具有更强的中文语义表征能力。因此,后续实验均采用“问答对分块”和 BGE-large-zh-v1.5 嵌入模型。

3.3 生成模块与量化影响评估

大模型的主要可调整参数为模型温度^[17] (Temperature),主要用于调整随机从生成模型中抽样的程度,即模型文本生成的随机性,温度越低,确定性越高^[13]。大模型温度常范围及其特点对比如表 5 所示。经测试,小参数模型对模型温度的参数调整更敏感,而大参数模型在检索模块提供足够知识的情况下模型温度的变化不影响最终结果的正确性。本次实践中选取的大模型温度为 1.0,以在保证一定创造性的同时侧重于事实性回答。

表 5 不同大模型温度对输出的影响

温度类型	温度范围	输出特点
较低温度	0.1 ~ 0.5	输出较为确定,可能较为单一
中等温度	0.5 ~ 1.5	平衡输出多样性和确定性
较高温度	1.5 ~ 2.0 或更高	输出更加多样和不可预测

同时,本文比较了不同参数规模的 Qwen1.5 模型 (14B vs 32B) 在 RAG 设置下的回答效果,如表 6 所示。

表 6 不同参数规模模型对回答效果的影响示例

模型 参数量	问题:如何更改邮箱密码?	人工评 估均分
14B	要更改集团邮箱(如:http://mail.sh.tobacco.com.cn)的密码,请按以下步骤操作: 1. 打开集团门户网站,通常是在浏览器地址栏中输入 http://group 门户网站。 2. 登录你的集团账户。如果还没有登录,需在右上角找到“登录”或“注册”入口。 3. 在登录后的界面,通常会有个人设置或账号管理的选项,找到这类功能后,会看到更改密码的链接或选项	3.2
32B	你可以在集团门户的右上角找到设置选项,然后在密码设置中更改你的邮箱密码。如果你忘记密码,可以通过手机验证码的方式在集团门户网站上重置新密码。记得,为了账户安全,密码应满足一定的复杂度要求,例如长度至少 8 位,包含大小写字母、数字和符号的组合	4.7

结果表明,Qwen1.5-32B 模型生成的答案更为准确、完整,更符合知识库描述。因此,后续量化实验基于 Qwen1.5-32B 模型进行。

对 Qwen1.5-32B 模型进行 FP16(作为基准)、INT8 和 INT4 量化,评估其对生成效果、推理速度和显存占用的影响。结果如表 7 所示。

表 7 不同量化方法对模型效率和硬件成本的影响^[14]

量化精度	Tokens/s	显存占用/GB	回答质量评估均分
FP16	35.8	65.3	4.7
INT8	48.2	31.7	4.6
INT4	61.5	19.2	4.5

从表 7 可见,INT8 量化对模型回答质量影响极小,同时显著降低了显存占用并提升了生成速度。INT4 量化进一步大幅降低显存占用(约 FP16 的三分之一),并显著提升了生成速度(较 FP16 提升约 71.8%),回答质量虽略有下降,但仍在可接受范围。综合考虑,INT4 量化为资源受限的私有化部署提供了极具吸引力的方案。

3.4 系统部署效果示例与分析

系统最终部署界面如图 2 所示。



图 2 系统实际部署界面

在下面的示例中,用户输入:“如何更改邮箱密码?”知识库检索输出示例如下:

```
{
  "#context#":
  "question: 门户、邮箱的密码及绑定的手机号如何更改、找回?
  answer: 可在集团门户内右上角设置中的密码设置以及手机绑定中更改;若忘记密码,可通过手机验证码的方式在集团门户网站上修改新密码。
  question: 如何规范设置、存储、更新用户密码?
```

```
  answer: 办公系统账号密码设置必须符合安全要求;
  严禁将用户密码信息告知他人或通过非可靠加密的电子化方式存档;
  严禁在系统中明文存储账号密码类信息;
  建议每三个月更新一次用户密码。"
}
```

然后通过将其拼贴入提示词的形式输入给大模型,具体形式如 2.4 节所述。

大模型通过将相关内容整合后输出回答:“您可以在集团门户网站内,右上角点击设置,然后选择密码设置进行更改。如果您忘记密码,可以通过手机验证码的方式在集团门户上重置新密码。”

该回答准确、全面地复述了知识库中的核心内容,并以清晰的 Markdown 格式呈现,用户体验良好。在测试集的 50 个问题中,采用 Qwen1.5-32B-INT4 模型的 RAG 系统,其生成的回答平均人工评估得分为 4.5 分,表明系统整体表现出色。

4 讨 论

本研究成功验证了基于 Qwen1.5-32B 和 BAAL/BGE-large-zh-v1.5 的 RAG 架构在企业知识库问答场景下私有化部署的可行性和有效性。实验表明,通过采用“问答对分块”等贴合业务数据形态的定制化策略,对提升检索准确率至关重要;高性能的词嵌入模型是保证检索效果的基础;模型量化(尤其是 INT4)能够在保证可接受问答效果的前提下,大幅降低硬件门槛,提升推理效率,对企业低成本实现 LLM 私有化具有重要应用价值。

为了进一步增强答案的可信度和可追溯性,以满足企业对答案严谨性的业务需求,本系统在后续迭代中考虑引入如 CitationQueryEngine^[18] 等机制,在返回答案的同时提供知识来源的引用。这对于企业内部知识的严谨性要求及用户对答案的信任构建至关重要。

4.1 实践应用要点

在将本系统应用于行业实践时,我们总结出以下核心要点,以确保 RAG 系统真正发挥价值。

1) 知识的深度与质量优先。RAG 系统的上限取决于知识库的质量。实践中,必须与业务部门紧密合作,不仅要保证知识的准确性,还要追求其完整性和权威性。

2) 知识的动态更新与维护机制。企业知识是动态变化的,新的产品、流程和问题会不断涌现。因此,必须设计一套高效的知识更新机制。通过增量式的分块、向量化和索引更新,确保 RAG 系统能够“学习”到

最新知识,避免信息滞后。

3) 建立闭环反馈与迭代优化路径。任何 AI 系统在初期都难以完美。应建立用户反馈机制,如对答案的“赞”或“踩”评价。这些反馈是宝贵的资源,可以用于发现知识库的盲区(或模型回答的偏差)。通过定期分析这些反馈,可以针对性地补充知识库内容、优化提示词工程,形成一个持续改进的良性循环。

4.2 技术方案泛化应用建议

本研究虽然基于特定案例,但其技术方案和实践经验对其他行业或企业开展类似工作具有普遍的参考意义。在进行技术方案移植或泛化时,建议重点关注以下技术细节:

1) 考虑 RAG 与参数高效微调(PEFT)的混合策略。对于复杂应用,RAG 负责提供精准、可溯源的事实性知识,解决模型“不知道”的问题;而 PEFT(如 LoRA)则可用于让模型学习特定行业的沟通风格、术语用法或特有的推理逻辑,实现“知识”与“能力”的双重适配。

2) 合理权衡模型选型与软硬件资源。企业应根据业务需求的复杂性、预期的用户并发量和响应时间要求,匹配合适的基座模型和量化策略。如本研究所示,32B 模型经 INT4 量化后可在 24 GB 显存的 GPU 上运行,显著降低了硬件门槛。

最后,LLM 生成内容的评估目前仍较多依赖人工,建立更完善、自动化的评估指标体系是未来研究的重要方向。

5 结 语

本研究以上海卷烟厂的实际需求为背景,设计并实现了一套基于 RAG 技术的私有化知识库问答系统。通过 Qwen1.5-32B 大模型和 BAAI/BGE-large-zh-v1.5 词嵌入模型的集成应用,并结合模型量化处理,系统地评估了各关键技术环节对系统性能的影响,验证了该技术方案在提升企业内部信息检索效率与准确性方面的潜力。实验结果为企业在资源受限条件下进行大语言模型私有化部署提供了有益的参考和实践指导。

成功的私有化部署不仅是技术的简单堆叠,更是技术与业务深度融合的系统工程。从知识库的精细化构建、模型的审慎选型与优化,到建立持续迭代的反馈闭环,每一步都对最终效果产生深远影响。

本次实践基于开源项目进行,现行的开源项目已经能够满足知识库部署的基本需求,但也会受到本次

研究所选开源大模型本身的限制。如 Ollama 不支持多模态模型的使用;Dify 不支持直接上传文档,不支持批量测试验证等。同时,我们发现大模型在垂直领域应用的难点依然是高质量数据的获取,这需要需求方的全力支持,从而为大模型的准确应用提供更准确的知识来源以及更及时的反馈。大语言模型的综合应用将在多模态能力加持下得到进一步增强。

RAG 始终是一种工程方式,最终实现突破的还是模型算法本身能力。2024 年,基于 MLP 结构对循环神经网络(RNN)进行优化的方案 KAN^[19]网络技术已经被验证。这项技术预示着在未来大模型的性能和效率将得到显著提升。

随着自然语言处理与多模态交互技术的深度融合,RAG 技术将向更智能、更动态的方向演进,通过强化意图识别的细粒度与上下文敏感度,突破纯文本限制,探索图像、语音、结构化数据等多模态知识的联合检索与跨模态推理^[20],构建意图识别与知识检索过程的可解释性框架,推动 RAG 技术在移动端、物联网等边缘设备的落地等方面的研究,将为 RAG 在开放域问答、对话系统、知识服务等领域提供更强大的技术支撑。

目前,大模型相关技术正处于快速发展期,相信随着对大模型本身的进一步优化以及大模型应用方式和框架的创新,以及基于大模型的应用场景的发掘和多模态能力的进一步增强,这一技术将为上海卷烟厂推动数字化转型和智能化升级提供更强大的驱动力。

参 考 文 献

[1] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems, 2017: 6000 - 6010.

[2] Chang Y, Wang X, Wang J, et al. A survey on evaluation of large language models[J]. ACM Transactions on Intelligent Systems and Technology, 2024, 15(3): 1 - 45.

[3] Hurst A, Lerer A, Goucher A P, et al. Gpt-4o system card [EB]. arXiv:2410.21276, 2024.

[4] 徐明. 生成式人工智能大模型的安全挑战与治理路径研究[J]. 信息通信技术与政策, 2025, 51(1): 10 - 19.

[5] 魏钰明, 贾开, 曾润喜, 等. DeepSeek 突破效应下的人工智能创新发展与治理变革[J]. 电子政务, 2025(3): 2 - 39.

[6] Zhang B, Liu Z, Cherry C, et al. When scaling meets llm finetuning: The effect of data, model and finetuning method [EB]. arXiv:2402.17193, 2024.

- corporated latent factorization of tensors for large-scale dynamic network analysis [C]//2021 China Automation Congress, 2021: 2980 – 2984.
- [17] Wang S, You M, Bo C, et al. Multi-dimensional QoS prediction for service recommendations[J]. IEEE Transactions on Services Computing, 2019, 12(1): 47 – 57.
- [18] Lin Z, Wu H. Dynamical representation learning for Ethereum transaction network via non-negative adaptive latent factorization of tensors [C]//2021 International Conference on Cyber-Physical Social Intelligence, 2021: 1 – 6.
- [19] Wu H, Luo X, Zhou M. Neural latent factorization of tensors for dynamically weighted directed networks analysis [C]//2021 IEEE International Conference on Systems, Man, and Cybernetics, 2021: 3061 – 3066.
- [20] Wu H, Luo X, Zhou M. Discovering hidden pattern in large-scale dynamically weighted directed network via latent factorization of tensors [C]//2021 IEEE 17th International Conference on Automation Science and Engineering, 2021: 1533 – 1538.
- [21] Chen M, Wu H, He C, et al. Momentum-incorporated latent factorization of tensors for extracting temporal patterns from QoS data [C]//2019 IEEE International Conference on Systems, Man and Cybernetics, 2019: 1757 – 1762.
- [22] Wang J, Tian F, Yu H, et al. Diversified non-negative matrix factorization for Multiview data representation[J]. IEEE Transactions on Cybernetics, 2018, 48(9): 2620 – 2632.
- [23] Li H, Chen N, Li L. Error analysis for matrix elastic-net regularization algorithms[J]. IEEE Transactions on Neural Networks and Learning Systems, 2012, 33(5): 737 – 748.
- [24] Zhang Z, Lai Z, Xu Y, et al. Discriminative elastic-net regularized linear regression[J]. IEEE Transactions on Image Processing, 2017, 26(3): 1466 – 1481.
- [25] Luo X, Wu H, Li Z. Neulft: A novel approach to nonlinear canonical polyadic decomposition on high-dimensional incomplete tensors[J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 35(6): 6148 – 6166.
- [26] Li S, Wen J, Luo F, et al. Time-aware QoS prediction for cloud service recommendation based on matrix factorization [J]. IEEE Access, 2018, 6: 77716 – 77724.
- [27] Ioannidis V, Zamzam A, Giannakis G, et al. Coupled graphs and tensor factorization for recommender systems and community detection[J]. IEEE Transactions on Knowledge and Data Engineering, 2021, 33(3): 909 – 920.
- [28] Bhanu M, Mendes-Moreira, Chandra J. Embedding traffic network characteristics using tensor for improved traffic prediction[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 22(6): 3359 – 3371.
- [29] Demšar J. Statistical comparisons of classifiers over multiple data sets[J]. Journal of Machine Learning Research, 2006, 7: 1 – 30.
- [30] Qin W, Wu H, Lai Q, et al. A parallelized, momentum-incorporated stochastic gradient descent scheme for latent factor analysis on high-dimensional and sparse matrices from recommender systems [C]//2019 IEEE International Conference on Systems, Man and Cybernetics, 2019: 1744 – 1749.
- [31] 王欢, 王永革. 基于 $L_{1/2}$ 正则化的超分辨率图像重建算法[J]. 计算机工程, 2012, 38(20): 191 – 194.
- ~~~~~
- (上接第 138 页)
- [7] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[J]. Advances in Neural Information Processing Systems, 2020, 33: 9459 – 9474.
- [8] 白培发, 黄宗浩, 王奕. 大模型在智慧医院的应用研究综述[J]. 计算机应用与软件, 2024, 41(7): 1 – 5, 19.
- [9] Hu E J, Shen Y, Wallis P, et al. Lora: Low-rank adaptation of large language models[J]. ICLR, 2022, 1(2): 3.
- [10] 贺梓然, 江波, 王晓龙. 改进检索增强与 LLM 思维链维修策略生成[J]. 计算机应用与软件, 2025, 42(3): 1 – 6, 83.
- [11] 唐嘉, 庞大巍, 刘书铭, 等. 大语言模型微调训练与检索增强生成技术在油气企业制度问答应用中的效果对比研究[J]. 数字通信世界, 2024(11): 104 – 106.
- [12] 高杨, 曹仰杰, 段鹏松. 神经网络模型轻量化方法综述[J]. 计算机科学, 2024, 51(S1): 23 – 33.
- [13] Dettmers T, Lewis M, Belkada Y, et al. Gpt3. int8(): 8-bit matrix multiplication for transformers at scale[J]. Advances in Neural Information Processing Systems, 2022, 35: 30318 – 30332.
- [14] Douze M, Guzhva A, Deng C, et al. The faiss library [EB]. arXiv:2401.08281, 2024.
- [15] Chang Y, Wang X, Wang J, et al. A survey on evaluation of large language models[J]. ACM Transactions on Intelligent Systems and Technology, 2024, 15(3): 1 – 45.
- [16] Finardi P, Avila L, Castaldoni R, et al. The chronicles of rag: The retriever, the chunk and the generator[EB]. arXiv: 2401.07883, 2024.
- [17] Renze M. The effect of sampling temperature on problem solving in large language models [C]//Findings of the Association for Computational Linguistics, 2024. 2024: 7346 – 7356.
- [18] Ng K K Y, Matsuba I, Zhang P C. RAG in health care: A novel framework for improving communication and decision-making by addressing LLM limitations[J]. NEJM AI, 2025, 2(1): AIra2400380.
- [19] Liu Z, Wang Y, Vaidya S, et al. Kan: Kolmogorov-arnold networks[EB]. arXiv:2404.19756, 2024.
- [20] 岳颀, 张晨康. 多模态场景下 AIGC 的应用综述[J]. 计算机科学与探索, 2025, 19(1): 79 – 96.