

面向动态知识库的多教师知识问答模型

张龙飞¹ 宋 扬^{1*} 白庆春²

¹(曲阜师范大学计算机学院 山东 日照 276805)

²(上海远程开放教育工程技术研究中心 上海 200000)

摘 要 针对已有知识库问答方法缺乏连续学习能力,难以在动态知识库上进行部署,提出一种基于多教师蒸馏与增量学习的动态知识库问答模型。该模型能够在学习新知识的同时保证对历史知识的记忆能力,实现连续学习。此外,受到多教师蒸馏的启发,设计一个多教师框架,利用多个不同的教师模型进一步优化知识蒸馏的效果。实验结果表明,该模型在三个标准数据集上达到了 91.02%、72.65% 和 73.82% 的准确率。

关键词 知识库问答 增量学习 知识蒸馏 师生网络

中图分类号 TP3

文献标志码 A

DOI:10.3969/j.issn.1000-386x.2026.02.027

MULTI-TEACHER KNOWLEDGE BASED QUESTION ANSWERING MODEL FOR DYNAMIC KNOWLEDGE BASE

Zhang Longfei¹ Song Yang^{1*} Bai Qingchun²

¹(School of Computer, Qufu Normal University, Rizhao 276805, Shandong, China)

²(Shanghai Engineering Research Center of Open Distance Education, Shanghai 200000, China)

Abstract Aiming at the lack of continuous learning ability of existing knowledge base question answering methods and difficulty on dynamic knowledge bases, we proposed a question answering model based on multi-teacher distillation and incremental learning dynamic knowledge base. The model could guarantee the memory ability of historical knowledge while learning new knowledge, and realized continuous learning. In addition, inspired by multi-teacher distillation, this paper designed a multi-teacher framework to further optimize the effect of knowledge distillation by using multiple different teacher models. Experimental results show that the model achieves accuracy rates of 91.02, 72.65, and 73.82 on three standard datasets.

Keywords KBQA Incremental learning Knowledge distillation T-S net

0 引 言

在自然语言处理中,知识库问答旨在通过查询知识库中的知识来回答自然语言问题^[1-2]。其一般流程为找到问题中的主体实体和关系^[3](可能不止一个),确定知识库^[4-6]中对应的三元组,以对象实体作为答案实体,并输出该实体作为答案。最近,相关研究尝试着在动态知识库中完成知识库问答任务^[7-8]。基于这种方法,问答系统就能通过不断更新的知识库,逐步扩

展其回答问题的能力^[9-10]。然而,动态知识库为了模拟真实世界的场景,在它内部的实体之间的关系 r 会随着时间的推移而变化,部分三元组可能会丢失。因此,这些三元组对应的问题在当前模型训练过程中会缺乏相应的历史知识。同时,由于模型对新知识的学习优先级更高,模型内部的部分有关旧知识学习的参数被覆盖,使得模型对旧知识的学习能力下降^[11-12]。因此,研究持续提升模型学习能力对优化知识库问答的性能在动态知识库上的部署效果十分重要。

对于历史知识的缺失和新知识学习对旧知识记忆

的干扰,常见的解决方法就是利用模型学习过的历史知识库和历史问题来重新训练一个健壮模型^[13-14]。但这要求模型在每次更新时都需要重复对所有先前问题和知识的训练。随着训练轮数的增加,模型对时间和内存的需求将呈指数增长。有学者提出在历史知识上仅对模型进行微调以代替再训练,借助已经训练好的 BERT^[15] 等大型模型来节省计算资源^[16-17]。但是,微调不适合在动态知识库上进行长期训练。由于微调方法会优先将模型的参数和输出调整到适应新任务的状态,导致每次训练后部分历史训练信息都被覆盖一部分,这使得预训练方法在解决模型对旧知识的学习能力下降问题上效果并不佳。基于增量学习的方法使用以往的模型为基础^[18-20],选择一部分重要的历史知识作为整个知识库的代表,让模型重新学习^[21],可以缓解缺失历史知识的问题。但是,这些历史知识数量很少,无法涵盖知识库中所需的所有内容,对于选择之外的历史知识,他们的方法仍然无法满足要求。

考虑到这一点,一个有效的解决方案是对于所有回答过的历史问题,模型都保留其相应的历史知识来学习当前训练过程中的历史问题。本文提出了一种面向动态知识库的多教师知识问答模型,通过将问题的三元组和对应的知识动态地结合起来作为历史知识来训练模型,解决了历史知识不足的问题。具体来说,该模型为每一轮中使用过的三元组 (s, r, o) 都构建一个三元组表,并通过一个基于知识的推理模型来进行反向推理,将历史问题联系上包含正确关系 r 的三元组 (s, r, o) 。通过这种方法,允许当前的模型在学习当前问题的同时获得三元组和问题训练来记忆历史知识,补充缺失的历史知识。在此基础上,本文还提出了一种多教师框架,允许模型在知识蒸馏的过程中使用多个教师模型进行知识蒸馏,并根据不同的问题来选择最适合的教师模型来优化教师-学生网络架构的整体性能。本文中的模型在当前最常见的三个 KBQA 数据集 SimpleQuestion、WebQuestion、WebQuestionSP 上进行了测试,并分别达到了 91.02%、72.65%、73.82% 的最好结果。实验结果证明,面向动态知识库的多教师知识问答模型相比于以往的知识库问答模型,在多轮数的学习中具有更好的性能。

1 相关工作

为了便于理解,本文首先介绍知识库问答和基于增量学习的 KBQA 的相关工作。

1.1 知识库问答

知识库问答是基于知识库来回答问题的自然语言

处理任务之一^[22-24]。在早期的研究工作中,由于自然语言问题包含的情感、语境等因素,通常需要花费大量的时间和计算资源才能训练出一个优秀的模型^[25-26]。随着神经网络的引入,模型的学习能力得到提升,知识库问答逐渐向着回答更复杂难解的问题的方向发展^[27-28]。例如,He 等^[29]使用 NSM 模型^[30]来学习中间监督信号以增强多跳问答。他们的方法使用教师-学生网络^[31],结合双向推理来解决中间推理结果不正确的问题,从而进一步提升 seq2seq 框架^[32]在问答任务的准确率。Wu 等^[6]使用一种基于 seq2seq 的语义解析方法,将问题类型识别问题转换为其他问题的思路^[33]。Cheng 等^[23]通过评估不属于问题本体的实体来评估基于 seq2seq 的模型,并在预定义的类别中,构建一个新的评分模块来完成知识库问答任务。但是,这些方法忽略了一个重要因素,那就是真实的知识库不是静态的。如果数据库发生变化,这些模型就需要重新训练。尽管这些模型在各个数据集上取得了优秀的性能,但它们无法更好地匹配现实世界的情况^[21]。

1.2 增量学习

知识库问答(KBQA)在静态知识库上取得了优异的成绩。但随着实际情况和事实的变化,知识库的内容也需要不断变化^[34]。在深度学习和机器学习中,增量学习适用于解决不断发展和变化的学习问题^[35]。近年来,增量学习的思想已被用于 NLP 任务上^[36-37]。增量学习要求在吸收新知识的同时保留、整合和优化对旧知识的记忆的能力^[38]。大多数时候,增量学习的核心问题是灾难性遗忘。当模型学习新知识时,它会忘记部分学习的知识^[39]。在当前的工作中,通常尝试使用知识蒸馏^[40]解决遗忘问题。使用知识蒸馏的目的是将先前的知识在联合训练条件下输入到师生网络架构中。该架构使用性能优越但训练过程复杂的大型模型来诱导性能较差但训练和部署速度更快的模型进行训练。通过该方法,大模型中的知识转移到小模型中,通过“交替训练”增强模型的学习能力。它为在知识问答中训练神经网络模型以解决现实世界知识的不断变化提供了新的思路。在回答简单问题时,该方法引入增量思维来解决灾难性遗忘模型,取得了较好的效果。

2 模型设计

2.1 模型架构

本文中提出的模型如图 1 所示。整个模型由多个深度学习模型组成的多教师架构和基于增量学习的推

理模型两部分组成。整个问答任务被分成 M 个阶段, 其中每个阶段对应的数据集都有差异, 这种差异表现为在每个阶段 $i(i \in (1, m])$ 中, 都包含有部分 $i-1$ 以及 $i-j(j < i)$ 阶段的部分问题, 这些问题在数据集中没有对应的知识。




图1 模型整体架构

模型的任务就是在一个完整的时间段内连续回答上述 M 个阶段的问题。在第一个阶段, 多教师架构的作用是将作为教师模型的 BERT 等大型模型的学习结果迁移到基于增量学习的推理模型上。后续阶段中, 基于增量学习的推理模型负责实现对历史问题以及当前问题的回答。对于以上两个阶段, 我们使用两个助教模型来优化它们的学习过程。

2.2 助教模型

如图2所示, 本文使用神经状态机 (Neural State Machine) 模型来实现助教模型的构建。神经状态机由一个指令模块和一个推理模块组成。指令模块向推理模块发送指令向量, 而推理模块则推断实体分布并学习实体表示。




图2 用于助教的神经状态机模型

对于当前的每一个问题 q , 模型使用 Glove 来获得 q 中每个词的嵌入 $\{i^k \mid k = 1, 2, \dots, n\}$, 并使用基于 LSTM 的编码器将它们编码成一组隐藏状态序列 $\{h_j \mid j = 1, 2, \dots, l\}$ 。在这里 n 和 l 分别是最大推理步数和序列长度。同时, 在实现知识库问答任务的神经状态机中, 还在指令模块中使用了注意力机制:

$$i^k = \sum_{j=1}^l a_j^k h_j \quad (1)$$

其中:

$$a_j^k = \text{Softmax}_j(\mathbf{W}_a(q^k \odot h_j) + b_a) \quad (2)$$

$$q^k = \mathbf{W}^k[i^{k-1}; q] + b^k \quad (3)$$

式中: $\mathbf{W}^k$ 、 $\mathbf{W}_a$ 为权重矩阵, b 为偏置项, 它们都是通过训练获得的。注意力机制目的是使模型在不同时间步长内学习指令向量时, 能够关注不同的特定部分。通过重复上述过程, 神经状态机在经过 n 个推理步骤后得到一个指令向量 $\{i^k\}_{k=1}^n$ 的列表。

接下来, 神经状态机的推理模块生成当前推理的中间实体分布和推理结果。这些中间实体是模型在 $k-1$ 步推理后得到的预测答案分布。它们的作用为: 1) 作为神经状态机第 k 步推理的初始状态; 2) 作为学生模型在第 $k-1$ 步推理的监督信息。推理组件的输入由当前步骤的指令向量, 以及从上一个推理步骤中获得的实体分布和实体嵌入组成。推理组件的输出包括预测的答案实体分布 p_k 和答案实体嵌入 e_k 。在神经状态机中, 为了得到训练所需的实体类型信息, 所有实体的初始化表示由以下方式进行:

$$e^0 = \sigma(\sum_{\langle s_1, r, o \rangle} r \mathbf{W}_T) \quad (4)$$

这里的 $\mathbf{W}_T$ 也是一个需要学习的参数。在这里, 神经状态机将实体的相邻关系作为实体的表征方式, 来减少有噪声实体的影响, 同时为实体提供更好的表示方法。神经状态机的推理过程如下:

$$m_{\langle s_1, r, o \rangle} = \sigma(i_k \odot \mathbf{W}_R r) \quad (5)$$

式中: $\mathbf{W}_R$ 是一个通过学习的参数, $\odot$ 为向量按位相乘。接下来, 推理模型对每个对象实体 o 对应的三元组 (s, r, o) , 将它们与可能为答案的相邻三元组进行匹配, 并根据它们在最后一个推理步骤中获得的注意力程度给它们分配权重:

$$\tilde{e}_k = \sum_{\langle s_1, r, o \rangle \in KG} p_{s_1, k-1} \cdot m_{\langle s_1, r, o \rangle}^k \quad (6)$$

式中: $p_{s_1, k-1}$ 是第 $k-1$ 轮推理后得到的实体 s_1 的相关程度。接下来, 神经状态机通过如下公式更新各个实体的表示:

$$e_k = \mathbf{W}_k([e_{k-1}; \tilde{e}_k]) + b_k \quad (7)$$

$$p_k = \text{softmax}(E^{(k)T} \mathbf{w}) \quad (8)$$

式中: $\mathbf{w}$ 是可学习参数。推理模块的输出为更新后的实体表示 E^k 和实体分布 p_k 。相比于以往的教师模型只提供最终的预测分布作为监督信息, 神经状态机的推理模块在中间步骤中显式地维护和学习问题的答案实体分布。通过学习性能更好的助教模型的中间实体分布, 学生模型能够更好地优化自身的推理路径。

2.3 基于增量学习的推理模型

对于回答历史问题这一任务,本文中采用了基于回放的增量学习方式,通过抽取与历史问题相关的三元组和问题本身来训练模型复习对历史问题的学习能力。由于我们的表格中不包含问题本身,在当前模型训练之前要先将问题与三元组进行匹配。但是在旧知识库直接用问题中的主题实体和答案在表中进行搜索是不合适的,因为不同的时间节点上实体之间的关系可能不同。这可能会引起训练误差。因此,本文设计了一种基于增量学习的推理模型。

基于增量学习的推理模型如图3所示。整个模型由历史问题推理模型和主推理模型两部分组成。历史模型的任务是对提取的历史问题进行推理,并获得其对应的知识三元组。主模型的任务是回答问题,完成知识库问答任务。同时,在基于增量学习的推理模型中还添加了一个神经状态机模型,作为助教来学习历史知识,并将历史知识迁移到当前回答历史问题的模型上。




图3 基于增量学习的推理模型

整个训练过程分为 N 个阶段 ($N > i$)。经过 D_{i-1} 阶段的训练后,主模型将回答的问题提取为历史问题 q_h 。同时,基于增量学习的推理模型将包含主题实体的三元组 $Triples(s, r, o)$ 提取到一个人工创建的三元组表 $Table_h$ 中作为历史知识。

$$Table_h = \sum Triples_x \quad (9)$$

式中: x 为使用过的三元组的数量。这些历史问题用于放入历史问题推理模型中,通过反向推理得到历史问题的对应关系。本文中使用 GRU 作为解码器-编码器的基本结构来实现反向推理模型:

$$u_h = \text{GRU}(e_1, e_2, \dots, e_n) \quad (10)$$

式中: u_h 为 GRU 编码历史问题产生的上下文向量。 e_n 为问题中各个实体的嵌入,它们是通过 glove 获得的。接下来,在解码器中,模型将上下文向量解码为问题对应的关系 r :

$$r = \text{GRU}(u_h) \quad (11)$$

最后,根据 r 与 s ,确定问题 q 对应的答案三元组 (s, r, o) ,它与问题组成历史知识。它们用来训练作为助教的神经状态机模型学习历史知识。

在主推理模型中,对于问题 q :

$$q = (e_1, e_2, \dots, e_{L_1}, e_{L_2}, \dots, e_n)$$

式中: e_n 为问题中的实体。模型将问题实体替换为 $\langle e \rangle$ 。

$$q = (e_1, e_2, \dots, \langle e \rangle, \dots, e_n) \quad (12)$$

这个过程是通过实体链接工具来完成的。其中 $\langle e \rangle$ 是随机嵌入向量,用来取代问题中的主要实体 s 。该操作是为了避免问题实体在关系预测过程中影响模型对整个句子的理解。即防止模型在训练过程中“作弊”。接下来,对于这些嵌入向量,我们使用 BiGRU 作为编码器来生成它们的上下文向量:

$$u_{qn} = \text{BiGRU}(e_1, e_2, \langle e \rangle, \dots, e_n) \quad (13)$$

$$u_{sn} = \text{BiGRU}(e_n, e_{n-1}, \langle e \rangle, \dots, e_1) \quad (14)$$

$$u_q = \text{attention}(u_{sn}, u_{qn}) \quad (15)$$

式中: u_q 是由不包含关键实体的问题生成的上下文向量。 u_{qn} 是 BiGRU 层的正向的输出, u_{sn} 为 BiGRU 当前时刻的反向的输出。由于 seq2seq 模型有一定的遗忘性,因此本文使用一个 BiGRU 作为编码器的主体,并连接正向和反向输出向量作为编码器的输出。在去除主题实体之后,问题中还有其他对问题理解很重要的实体,模型使用注意力机制 attention 来识别和增强这些实体在问题中的地位。然后,对于已经确定的主题实体 s ,本文使用 TransH 将表中与这些主题实体 s 相关的关系 r 嵌入,得到 R_n ,其中 $R_n = (r_1, r_2, \dots, r_n)$ 。而实体 s 本身的实体类型也被嵌入为 t_s ,最终得到 u_s 。

$$u_s = \text{GRU}(t_s, R_n) \quad (16)$$

最后的输出是 u_s 和 u_q 的和:

$$u = u_s + u_q \quad (17)$$

在解码部分,使用一个普通的 GRU 网络作为解码器来处理输入向量 u 。对于每个 u ,我们最终得到每个关系 r 的预测分布为:

$$\text{output} = \text{GRU}(u) \quad (18)$$

对于得到的对应关系 r ,它们在表中对应的三元组会被查询出,作为问题对应的知识库中的历史知识。在接下来 D_i 中,对于刚刚获得的历史知识和历史问题,主模型重新学习它们,这个过程是助教模型和主模型的共同训练下完成的。主模型损失函数如下:

对于得到的对应关系 r ,它们在表中对应的三元组会被查询出,作为问题对应的知识库中的历史知识。在接下来 D_i 中,对于刚刚获得的历史知识和历史问题,主模型重新学习它们,这个过程是助教模型和主模型的共同训练下完成的。主模型损失函数如下:

$$\mathcal{L}_1 = D_{\text{KL}}(\tilde{p}_i^1, p_{\text{ground truth}}) \quad (19)$$

$$\mathcal{L}_2 = D_{\text{JS}}(\tilde{p}_i^1, \tilde{p}_i^s) \quad (20)$$

$$\mathcal{L}_3 = D_{\text{KL}}(\tilde{p}_i^s, p_{\text{ground truth}}) \quad (21)$$

$$\mathcal{L}_m = \mathcal{L}_1 + \mathcal{L}_2 + \mathcal{L}_3 \quad (22)$$

式中: D_{KL} 为库背-莱布勒(KL)散度,是一种可用来衡量两个概率分布相似性的指标。 D_{JS} 为詹森-香农散度,它以对称的方式度量两个分布之间的差值。 $\tilde{p}_i^t$ 和 $\tilde{p}_i^s$ 为助教模型和主模型的预测结果。 $\mathcal{L}_1$ 为教师在真实数据上的损失函数。同时还考虑了学生模型的预测和助教模型的监督信号之间的损失 $\mathcal{L}_2$,以及主模型的实际损失 $\mathcal{L}_3$ 。最后总损失为它们的和 $\mathcal{L}_m$ 。

2.4 多教师-助教框架

由于本文中的增量模型建立在知识蒸馏方法基础上,在知识蒸馏中,影响学生模型性能的一个重要因素是教师模型预测的准确率。本文提出了一种使用结合多教师与助教的知识蒸馏框架,聚合并利用多个教师的预测分布作为训练信息来进一步提升助教模型的学习能力。

如图4所示,多教师-助教框架由多教师框架与助教模型两部分组成。多教师框架作为助教模型的教师,助教作为学生。在作为助教的神经状态机模型在进行第 k 步推理时,对于所有使用到的 i 个教师模型,在训练层,教师模型以隐藏状态序列 h_j 为输入,预测答案实体 E_i 与预测概率 p_i^t 。在输出层,每个预测概率 p_i^t 通过一个温度参数 $T(T \gg 1)$ 来软化分布概率,平滑处理预测得到的标签:

$$\tilde{p}_i^t = \frac{\exp(p_i^t/T)}{\sum_j \exp(p_j^t/T)} \quad (23)$$




图4 多教师-助教框架

在得到对应的预测概率 t_i 后,为了有效地聚合多个教师的预测分布,框架首先计算教师预测和真实结果之间的差异,为不同的教师模型分配反映其样本置信度的不同权重:

$$\mathcal{L}_n = D_{KL}(\tilde{p}_i^t, p_{ground\ truth}) \quad (24)$$

式中: $p_{ground\ truth}$ 代表真实分布。为了获得该真实分布,对于 k 步中获得的答案实体,如果它是真实正确答案,那么它在最终分布中被分配的概率 $1/k$ 。同时,模型计算预测与真实标签之间的交叉熵损失,基于它们的置信度确定分配给不同教师模型权重值。

$$l_{CE, p_i} = - \sum_{c=1}^C y_c \log(\sigma(\tilde{p}_i^t)) \quad (25)$$

式中: c 是预测结果的类标签, y 为真实结果。

对于每个教师,它们对应的权重 w 计算方式如下:

$$w_{KD, k} = \frac{1}{i-1} \left(1 - \frac{\exp(l_{CE, p_i})}{\sum_j \exp(l_{CE, p_j})} \right) \quad (26)$$

最终,教师在 k 轮上的总体预测如下并用计算出的权重进行聚合。

$$p_i = - \sum_{i=1}^i w_{KD, k} \sum_{c=1}^C \tilde{p}_i^t \log(\sigma(p_i)) \quad (27)$$

这里的 p_i 为助教模型的预测结果。最终,助教模型的损失函数为:

$$l_{at} = \sum_{k=1}^{n-1} D_{KL}(p_{at, t}, p_{i, k}) \quad (28)$$

对于知识蒸馏模型,教师的准确率决定了学生模型的学习能力上限。尽可能地提升教师模型的学习能力对于提升基于增量学习的框架来说至关重要。由于现有的模型,如BERT、GPT-2等大型模型并没有专门考虑匹配学生模型,同时它们的规模非常庞大,难以直接迁移到轻量级的学生模型上,需要作为缓冲的助教模型。同时,单一教师很难适配不同的问答任务,如单跳问题的模型很难回答多跳问题。因此,本文提出了一种联合多教师模型与助教模型的教师框架,基于多个教师来进行训练,并以助教模型作为中间模型。学生模型学习到的知识来自于助教模型,缓解了教师与学生模型之间性能差距。同时,我们通过设置置信度,为表现更好的教师模型选择更大的权重,并基于神经状态机的结构,不再只将最终结果作为传递的信息,而在每一步推理中都进行学生对教师的学习,从而优化整个推理过程。

3 实验

3.1 实验环境

本文所使用开发环境是基于PyTorch搭建的。PyTorch是由Facebook创立的神经网络框架,它在机器学习领域有广泛的应用。本文所使用的PyTorch版本为1.9.0,使用的Python版本为3.9。

3.2 数据集

本文所用数据集为SimpleQuestion、WebQuestion和WebQuestionSP。

SimpleQuestion是一个包含大量简单问题的数据集,这些问题在知识库中被手动注释,以根据事实生成匹配的问题。该数据集的答案来自Freebase。数据

集包含 108 442 条数据,其中训练集占 70%,为 75 910 条信息;验证集占 10%,为 10 845 条信息;测试集为 21 687 条信息,占 20%。

WebQuestion 是一个基于 Google suggest API 构建的数据集。该数据集包含大量简单和复杂问题。它由包含 3 000 个问题的训练集、778 个问题的验证集和 2 032 个问题的测试集组成。

WebQuestionSP 是 WebQuestion 的一个子集,共包含 4 737 条训练信息。与之前的数据集相比,WebQuestionSP 包含更多的结构上更加复杂、更难回答的问题。值得注意的是,WebQuestion 和 WebQuestionSP 并没有给定的关系 r ,因此本文中搜索并选择每个实体 s 和 o ,并重构三元组 (s, r, o) 来完成任

务。在该数据集中,问题的最多查询跳数被设置为 3。

考虑到这些数据集不能反映现实世界数据的变化,本文对三个数据集进行了以下改进:首先,随机重新分配数据集中的问题及其对应的答案,使相似的问题-答案组合尽可能不相邻;接下来,构造五个新的小数据集 $D_i(i = 1, 2, 3, 4, 5)$ 。对于数据集中的问题 q ,将其均匀分布到每个小数据集 D_i 中,构成问题集 Q_i 。同时,只将知识库中对应的知识分配到相应的问题数据集。接下来,从每个小问题集 Q_i 的前一个问题集 Q_{i-1} 中抽取少量问题,添加到 Q_i 中。这样做的目的是模拟模型来回答前面的问题。与此同时,这些问题被标记以表明它们来自哪个数据集。完成后得到五个小数据集。训练、验证和测试集的比例为 8:1:1,如表 1 所示。

表 1 数据集			
轮	SimpleQuestion	WebQuestion	WebQuestionSP
D1	18 001/2 250/2 251	1 856/232/232	1 519/189/190
D2	22 055/2 757/2 757	1 862/232/232	1 518/189/190
D3	10 768/1 346/1 346	1 859/232/232	1 520/189/190
D4	11 672/1 459/1 460	1 859/232/232	1 521/189/190
D5	15 961/1 995/1 996	1 860/232/232	1 519/189/190

3.3 参数设置与评价指标

在实体链接模块中使用 Word2vec 作为单词嵌入工具。BiGRU-CRF 模型的字嵌入维数和字符编码向量的嵌入维数均设为 50。编码器中 GRU 的状态维数和输入维数均为 100。在解码器中,BiGRU 的状态维数设置为 200,其输入为 200 维词向量与 10 维位置向量的连接,表示实体在询问句子中对应的位置。解码器对应的状态维度设置为 300。模型使用 Adam 优化

器优化所有模型,批次大小设置为 128,学习率设置为 0.005。在多教师模型中,使用 BERT-base 和双向 NSM 作为教师模型。在 BERT 中,批大小为 128。辍学率设置为 0.1,学习率为 0.005。

本文中用准确率 ACC 和 F1 值来评价模型正确预测答案的能力。其中:

$$F_1 = \frac{2P_{\text{recision}} \times R_{\text{ecall}}}{P_{\text{recision}} + R_{\text{ecall}}}$$

(29)

式中: P_{recision} 为预测为正确的回答中,真实值为正确的比例,而 R_{ecall} 即为在所有的真实值为正确的答案中,正确答案所占的比例。

3.4 基准模型

- 本文采取以下模型作为基准对比模型。
- 1) LSTM^[43] 是一种循环神经网络。将门控机制与长、短时记忆相结合,在一定程度上解决了 RNN 梯度消失的问题。
- 2) APVA-TURBO^[20] 创建了一个新的 KBQA 框架“APVA-TURBO”,并提出了一个框架。它包括一种验证关系和路径标签是否正确的机制,以增强模型。同时,在迭代过程中采用“涡轮训练”联合训练方法增强关系预测模块。
- 3) PullNet^[45] 是一种基于信息检索方式实现 KBQA 的方法。作者提出了一种新的思想“Pull”,它允许模型自动学习提取图中与问题相关的子图。此外,作者还使用 GCN 对节点进行表示学习,以判断结果是否正确。
- 4) BERT^[15] 是目前最优秀的深度学习模型之一。它允许对未标记文本进行预训练,并通过调优各层的参数来学习上下文表示。对于 BERT,只需要增加输出层并进行微调,就能实现各种 NLP 任务。
- 5) Cheng 等^[23] 提出了一种基于固有评分模块的方法来提高实体识别。具体而言,作者设计了一个推理模块,将注意机制与记忆能力相结合,对问句中的单词进行评分。同时,为了提高推理模块的泛化性,基于迁移学习的思想,采用多任务学习的方法丰富了推理模块的表示形式。
- 6) 双向 NSM^[29] 是一种基于 NSM 模型的知识问答模型。作者提出了一种新的师生结合方法中的多跳 KBQA 模型。它利用正向和反向推理来增强对中间实体分布的学习。通过考虑双向推理,该模型产生了更可靠的中间监督信号,从而缓解了伪推理的问题。
- 7) 增量 KBQA^[21] 首先在 KBQA 中引入增量的思想。该模型通过知识蒸馏和协同范例选择的方法扩展了模型的学习能力。

3.5 实验结果与分析

1) 与基线模型的对比。本文所提出的模型将与动态知识库下的其他 KBQA 模型进行比较。在本实验

中,为每个数据集设置了 10% 的历史问题,以确保反映历史问题对模型训练的影响。实验结果如表 2 – 表 4 所示。

表 2 模型在 SimpleQuestion 数据集上的表现

模型	D1		D2		D3		D4		D5		AVG	
	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1
LSTM	83.34	75.51	75.01	67.96	67.51	61.16	61.43	55.66	55.90	50.65	68.64	62.19
APVA-TURBO	81.50	76.10	73.51	68.59	66.24	61.76	60.36	56.23	54.95	51.15	67.31	62.77
PULLNET	91.25	85.91	83.95	79.04	77.23	72.72	71.82	67.63	66.79	62.90	78.21	73.64
BERT	92.35	87.10	84.96	80.13	78.16	73.72	72.69	68.56	68.33	64.45	79.30	74.79
Cheng 等	90.32	83.60	83.09	76.91	76.44	70.76	71.09	65.81	66.82	61.86	77.55	71.79
BiNSM	92.52	87.40	85.12	80.41	78.31	73.98	72.83	68.80	68.46	64.67	79.45	75.05
Li 等	89.25	82.40	86.52	81.20	83.15	78.01	83.55	77.68	83.72	77.64	85.24	79.39
本文	92.68	87.41	90.83	85.65	90.63	86.07	90.45	86.01	90.53	86.16	91.02	86.30

表 3 模型在 WebQuestion 数据集上的表现

模型	D1		D2		D3		D4		D5		AVG	
	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1
LSTM	53.58	46.51	48.22	41.86	43.40	37.67	39.49	34.28	35.94	31.19	44.13	38.30
APVA-TURBO	67.50	63.20	61.43	57.51	55.90	52.33	51.43	48.14	47.32	44.29	56.72	53.09
PULLNET	69.65	65.91	64.08	60.64	58.95	55.79	54.82	51.88	54.82	48.25	60.46	56.49
BERT	71.48	66.50	64.84	60.26	59.65	55.44	55.47	51.56	52.14	48.47	60.52	56.25
Cheng 等	70.20	58.60	64.58	53.91	59.41	49.60	55.25	46.13	51.94	43.36	60.28	50.32
BiNSM	71.51	66.40	65.79	61.09	60.53	56.20	56.29	52.27	52.91	49.13	61.41	57.02
Li 等	68.21	61.40	63.80	56.40	63.41	55.00	62.70	54.00	61.48	53.20	63.92	56.00
本文	73.99	66.90	72.56	67.91	72.44	67.40	71.96	65.57	72.32	64.36	72.65	66.43

表 4 模型在 WebQuestionSP 数据集上的表现

模型	D1		D2		D3		D4		D5		AVG	
	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1
LSTM	51.37	42.51	46.23	38.26	41.61	34.43	37.87	31.33	34.46	28.51	42.31	35.01
APVA-TURBO	54.29	45.42	49.40	41.33	44.95	37.61	41.35	34.60	38.04	31.83	45.61	38.16
PULLNET	68.15	56.91	62.70	52.36	57.68	48.17	53.64	44.80	49.89	41.66	58.41	48.78
BERT	72.23	64.50	63.73	56.58	58.63	52.05	54.53	48.41	51.26	45.51	59.48	52.81
Cheng 等	72.55	57.60	66.75	52.99	61.41	48.75	57.11	45.34	53.68	42.62	62.30	49.46
BiNSM	74.30	67.40	68.36	62.01	62.89	57.05	58.49	53.06	54.98	49.88	63.80	57.88
Li 等	69.00	61.90	62.63	55.53	62.00	54.90	61.12	54.02	60.41	53.31	63.03	55.93
本文	76.22	69.22	73.79	66.82	73.57	66.54	73.07	66.06	72.47	65.33	73.82	66.79

对于现有的模型,如双向 NSM 和 Bert,它们基于预训练和其他专门优化当前学习的策略,在现有的知识库问答任务上有很好的表现。如双向 NSM,它在三个数据集上达到了 92.52%、71.51% 和 74.3% 的最佳准确率。并且,使用大数据集进行 BERT 预训练的准确率也达到了 92.35% 的准确率,远高于以往的训练方法。同时,在多跳任务中,双向 NSM 通过生成更可

靠的中间监督信号,缓解了伪推理,在三个数据集上达到了 92.52%、71.51% 和 74.3% 的最佳精度。但在后续训练过程中,这些模型的性能都有一定程度的下降。这是由于知识库中历史知识的缺失,导致模型无法准确地回答这些问题。同时,可以看到增量 KBQA 模型具有更好的平均性能。尽管未能在三个数据集上实现 SOTA,但 SimpleQuestion 上的第一轮和

第五轮模型训练之间的差异仅为 4 百分点。增量式 KBQA 借助少量的历史知识记忆以前学过的内容,确保新问题的训练不被打扰回答问题。但是,由于增量 KBQA 只选择历史知识的一小部分作为范例,因此很难覆盖这个范围内的整个知识库。这使得第一轮和第二轮在 WebQuestionSP 上的准确率相差了 7.1 百分点。

本文提出的模型考虑了上述问题。依靠基于框架增量学习的知识库问答模型,以及多教师,该模型在三个数据集上的最终和平均结果达到了最好的平均精度和 F1 分数,在 WebQuestionSP 上,比当前 SOTA 模型的性能高出 6%。此外,在三个数据集上,模型中第一轮和第五轮训练之间的差距仅为 3.75 百分点,高于以往所有的模型。同时,为了验证提供的历史知识是有效的,而不是其他方法提高模型的性能,还测试了去掉历史问题推理模型,以探究在没有任何历史信息的情况下训练模型的影响。上述实验结果表明,本文中的改进是有效的。

2) 消融实验。上述实验表明,本文提出模型在实现动态知识库中的 KBQA 方面有显著的性能改进。接

下来部分将验证模型中多教师框架与助教模型在基于动态知识库的问答中的有效性。

首先对多教师框架的效果进行验证。为了验证多教师框架对增量学习中的知识蒸馏是否具有优化效果,本文测试了单独使用不同的教师模型和使用多教师框架之间的性能差距。如表 5 – 表 7 所示,在使用不同的教师模型后,基于 BiGRU 模型的性能有了明显的提升,如使用 BERT-base 作为教师后,学生模型在三个数据集上均有 1 百分点 ~ 3 百分点之间的性能提升。这验证了知识蒸馏在基于增量学习的知识库问答上的效果。但是,由于教师-学生网络的结构限制,学生模型学习到的知识均来源于教师模型,这使得学生模型的性能无法超过教师模型,并且教师模型如果存在误差,那么这个误差也会传递到学生模型中。同时,在不同的任务上,每个教师模型的表现并不相同,考虑教师和学生的适配也影响模型训练的效果。本文提出的多教师蒸馏方法考虑了这一问题,通过结合多个教师模型的知识来教导学生模型对知识学习,避免了因结构缺陷和教师本身性能不足带来的问题。

表 5 使用不同教师模型在 SimpleQuestion 数据集上对模型训练的影响

模型	D1		D2		D3		D4		D5		AVG	
	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1
BiGRU	89.98	84.70	87.74	81.78	86.85	81.08	85.96	80.66	85.71	78.54	87.25	81.35
Pullnet	91.15	85.87	89.02	83.68	87.92	82.51	87.50	82.79	87.09	80.79	88.54	83.13
双向 NSM	91.80	86.52	89.76	84.53	88.91	83.69	88.53	83.83	88.15	83.65	89.43	84.44
BERT	92.48	87.20	90.63	85.45	90.43	85.87	90.25	85.81	90.33	85.96	90.82	86.06
多教师蒸馏	92.68	87.41	90.83	85.65	90.63	86.07	90.45	86.01	90.53	86.16	91.02	86.30

表 6 使用不同教师模型在 WebQuestion 数据集上对模型训练的影响

模型	D1		D2		D3		D4		D5		AVG	
	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1
BiGRU	69.49	62.40	67.25	61.29	65.36	60.59	66.47	60.17	65.22	58.05	66.76	60.86
Pullnet	70.99	63.90	68.86	63.52	66.76	62.35	68.34	62.63	66.93	60.63	68.38	62.97
双向 NSM	72.11	65.02	70.07	64.84	68.22	64.00	69.84	64.14	68.46	63.96	69.74	64.75
BERT	72.19	65.10	70.76	66.11	70.64	65.60	71.16	63.77	70.52	62.56	71.05	64.83
多教师蒸馏	73.99	66.90	72.56	67.91	72.44	67.40	71.96	65.57	72.32	64.36	72.65	66.43

表 7 使用不同教师模型在 WebQuestionSP 数据集对模型训练的影响

模型	D1		D2		D3		D4		D5		AVG	
	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1
BiGRU	72.22	65.22	69.40	61.62	68.49	60.28	67.28	59.42	66.35	56.55	68.74	60.62
Pullnet	74.24	67.24	71.53	64.37	70.41	62.56	69.67	62.40	68.58	59.65	70.89	63.24
双向 NSM	75.21	68.21	72.59	65.54	71.72	64.06	71.02	63.76	69.96	62.83	72.10	64.88
BERT	74.65	67.65	72.22	65.25	72.00	64.97	71.50	64.49	70.90	63.76	72.25	65.22
多教师蒸馏	76.22	69.22	73.79	66.82	73.57	66.54	73.07	66.06	72.47	65.33	73.82	66.79

接下来,为了验证助教模型对基于增量学习的知识问答是否也具有增强效果,本文还测试了使用助教模型与未使用助教模型的模型之间的性能差异。如表 8 – 表 10 所示。在第一轮中,模型很好地回答了问题。但是到了第二轮,由于缺少助教作为教师与学生之间的缓冲,学生模型无法有效地学习到教师传递下

来的知识,模型的性能开始下降。无助教的模型在三个数据集的平均准确率下降了 2 个百分点左右。同时,在本文中通过使用助教模型来作为具有庞大参数量和答案向量空间的教师模型与轻量级的学生模型之间的中间模型,以确保之前训练的知识能够很好地转移到当前学习历史知识的模型中。

表 8 使用不同教师模型在 SimpleQuestion 数据集上对模型训练的影响

模型	D1		D2		D3		D4		D5		AVG	
	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1
有助教	92.68	87.40	90.83	85.65	90.63	86.07	90.45	86.01	90.53	86.16	91.02	86.30
无助教	92.68	87.40	88.64	83.43	85.97	80.95	85.72	78.88	85.59	78.84	87.49	81.34

表 9 使用不同教师模型在 WebQuestion 数据集上对模型训练的影响

模型	D1		D2		D3		D4		D5		AVG	
	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1
有助教	73.99	66.90	72.56	67.91	73.44	67.40	71.96	65.57	72.32	64.36	71.32	72.11
无助教	73.99	66.90	69.79	60.73	69.55	59.73	69.47	58.40	69.21	57.60	70.40	60.67

表 10 使用不同教师模型在 WebQuestionSP 数据集对模型训练的影响

模型	D1		D2		D3		D4		D5		AVG	
	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1
有助教	76.22	69.22	73.79	66.82	73.57	66.54	73.07	66.06	72.47	65.33	73.82	66.79
无助教	76.22	69.22	72.60	63.16	71.19	60.98	71.06	60.61	70.94	59.87	71.84	61.64

4 结 语

本文提出了一种基于多教师蒸馏与增量学习的动态知识库问答模型来解决基于动态知识库的 KBQA 任务中缺乏历史知识的问题。通过使用三元组和历史问题的组合作为历史知识来补充缺失的知识。此外,还提出了一种多教师框架的优化策略来完善这项任务。三个标准集的实验结果表明,该模型在平均准确率和 F1 分数方面优于以前的 KBQA 模型。通过这项研究,KBQA 可以更好地部署在真实的动态场景中。未来,该项研究将专注于在多跳任务上优化模型,并尝试使用不同的教师模型,在不同语言的任务上进行探索,研究教师模型的优化效果是否能应用在小语种问答系统上。

参 考 文 献

[1] 王守会,覃 飙. 知识库问答系统研究进展[J]. 小型微型计算机系统,2021,42(9) :1793 – 1801.

[2] Yao X, Durme B V. Information extraction over structured data: Question answering with freebase[C]//Meeting of the

Association for Computational Linguistics, 2014: 2107 – 2114.

[3] 刘杰,白尚旺,陆望东,等. 基于 Word2vec 和句法规则的自动问答系统问句相似度研究[J]. 计算机应用与软件, 2021,38(3) :169 – 174,201.

[4] Li D, Wei F R, Zhou M, et al. Question answering over freebase with multi-column convolutional neural networks [C]//Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing,2015:260 – 269.

[5] Carlini N, Tramer F, Wallace E, et al. Extracting training data from large language models[EB]. arXiv:2012. 07805, 2020.

[6] Wu L J, Wu P Y, Zhang X W. A Seq2seq-based approach to question answering over knowledge bases[C]//Joint International Semantic Technology Conference,2020:170 – 181.

[7] 刘园园,李劲华,赵俊莉. 基于语义解析的领域问答系统的设计与实现[J]. 计算机应用与软件,2021,38(11) :42 – 48,97.

[8] 邵曦,陈明. 结合 Bi-LSTM 和注意力模型的问答系统研究 [J]. 计算机应用与软件,2020,37(10) :52 – 56.

[9] Wu T Y, Swaminathan G, Li Z, et al. Class-incremental

- learning with strong pre-trained models[EB]. arXiv:2204.03634,2022.
- [10] Yin H X, Molchanov P, Li Z Z, et al. Dreaming to distill: data-free knowledge transfer via deepinversion [C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2020: 8712 – 8721.
- [11] 韩纪东,李玉鑑. 神经网络模型中灾难性遗忘研究的综述[J]. 北京工业大学学报,2021,47(5):551 – 564.
- [12] 刘冰瑶,刘进锋. 增量学习研究综述[J]. 现代计算机,2022,28(13):72 – 75,91
- [13] Perez-Rua J M, Zhu X T, Hospedales T, et al. Incremental Few-Shot Object Detection[EB]. arXiv:2003.04668,2020.
- [14] Berg H, Hall S M, Bhalgat Y, et al. A prompt array keeps the bias away: Debiasing vision-language models with adversarial learning[EB]. arXiv:2203.11933,2022.
- [15] 陈旻杰,魏轩,郑莹,等. 基于 BERT 的智能问答系统[J]. 数字技术与应用,2022,40(1):161 – 163.
- [16] Liu P F, Yuan W Z, Fu J L, et al. Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing[EB]. arXiv:2107.13586,2021.
- [17] Sun C, Qiu X P, Huang X J, et al. How to fine-tune BERT for text classification? [C]//China National Conference on Chinese Computational Linguistics,2019:194 – 206.
- [18] Zhou X J, Wan X J, Xiao J G. Attention-based LSTM network for cross-lingual sentiment classification[C]//Conference on Empirical Methods in Natural Language Processing, 2016:247 – 256.
- [19] Hao Y C, Liu H, He S Z, et al. Pattern-revising enhanced simple question answering over knowledge bases[C]//International Conference on Computational Linguistics. Association for Computational Linguistics,2018:3272 – 3282.
- [20] Wang Y, Zhang R C, Xu C, et al. The APVA-TURBO approach to question answering in knowledge base[C]//International Conference on Computational Linguistics,2018:1998 – 2009.
- [21] Li Y Q, Li W J, Nie L Q. Incremental knowledge based question answering[EB]. arXiv:2101.06938,2021.
- [22] Wu L, Wu P, Zhang X. A Seq2seq-based approach to question answering over knowledge bases[C]//Joint International Semantic Technology Conference,2020:170 – 181.
- [23] Cheng L, Chen Z H, Ren J T. Enhancing question answering over knowledge base using dynamical relation reasoning [C]//International Joint Conference on Neural Networks, 2020:1 – 8.
- [24] 蒲伟,王恒. 基于自然语言处理的问答系统综述[J]. 科技创新与应用,2021,11(22):77 – 79.
- [25] Hudson D A, Manning C D. Learning by Abstraction: The neural state machine[EB]. arXiv:1907.03950,2019.
- [26] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[EB]. arXiv:1503.02531,2015.
- [27] 周高峰,高盛祥,余正涛,等. UTMCA:融合多任务的复杂问答模型[J]. 小型微型计算机系统,2021,42(9):1830 – 1836.
- [28] 包芳,张炎凯,王士同. 基于在线增量学习的实时人脸跟踪算法[J]. 计算机应用与软件,2016,33(5):270 – 273,297.
- [29] He G L, Lan Y S, Jiang J, et al. Improving multi-hop knowledge base question answering by learning intermediate supervision signals[EB]. arXiv:2101.03737,2021
- [30] 冯钧,李艳,杭婷婷. 问答系统中复杂问题分解方法研究综述[J]. 计算机工程与应用,2022,58(17):23 – 33.
- [31] 李文煜,帅仁俊,郭汉. 克服小样本学习中灾难性遗忘方法研究[J]. 计算机应用与软件,2020,37(7):136 – 141,147.
- [32] Sutskever I, Vinyals O, Le Q V. Sequence to sequence learning with neural networks[C]//28th International Conference on Neural Information Processing Systems, 2014: 3104 – 3112.
- [33] Zhang X, Zhao J B, Lecun Y. Character-level convolutional networks for text classification[EB]. arXiv:1509.01626, 2015.
- [34] Shan G X, Xu S Y, Yang L, et al. Learn#: A novel incremental learning method for text classification[J]. Expert Systems with Applications,2020,147:113198.
- [35] Rebuffi S A, Kolesnikov A, Sperl G, et al. iCaRL: Incremental classifier and representation learning[EB]. arXiv:1611.07725,2016.
- [36] Mishra A, Marr D. Apprentice: Using knowledge distillation techniques to improve low-precision network accuracy[EB]. arXiv:1711.05852,2017.
- [37] Yin W P, Yu M, Xiang B, et al. Simple question answering by attentive convolutional neural network [EB]. arXiv:1606.03391,2016.
- [38] Castro F M, Marín-Jiménez M J, Guil N, et al. End-to-end incremental learning[EB]. arXiv:1807.09536,2018. Keywords Parisi G I, Kemker R, Part J L, et al. Continual life-long learning with neural networks: A review [J]. Neural Networks,2019(113):54 – 71.
- [39] Gou J P, Yu B S, Maybank S J, et al. Knowledge distillation: A survey[EB]. arXiv:2006.05525,2020.
- [40] Shi X, Chen Z, Wang H, et al. Convolutional LSTM network: A machine learning approach for precipitation nowcasting[EB]. arXiv:1807.09536,2015.
- [41] Sun H, Bedrax-Weiss T, Cohen W. PullNet: Open domain question answering with iterative retrieval on knowledge bases and text[C]//Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing,2019:2380 – 2390.